

生成式代理：人类行为的交互式模拟

Generative Agents: Interactive Simulacra of Human Behavior

Joon Sung Park、Joseph C. O’ Brien、Carrie J. Cai、Meredith Ringel Morris、Percy Liang、Michael S. Bernstein

Stanford University、Google Research、Google DeepMind；UIST 2023；arXiv:2304.03442v2（2023年8月6日）

译本说明：本文件依据论文公开 PDF 制作中文译排版。正文、图题、表述和附录按原论文结构翻译；作者名、引用编号、DOI 及参考文献书目信息保留原文形式，以便准确检索。论文中的原始示意图未重新绘制，图题和正文已翻译。

摘要

可信的人类行为代理可以服务于沉浸式环境、人际沟通演练空间和原型设计工具等交互应用。本文提出生成式代理（generative agents）：能够模拟可信人类行为的计算机软件代理。生成式代理会起床、做早餐、去工作；艺术家会绘画，作者会写作；代理会形成观点、注意到彼此并发起对话；它们会记住并反思过去的日子，同时规划下一天。

为实现生成式代理，我们提出一种扩展大语言模型的架构：用自然语言保存代理经历的完整记录，在时间推移中将记忆综合为更高层次的反思，并动态检索这些记忆来规划行为。我们在受《模拟人生》启发的交互式沙盒环境中实例化该架构，让用户通过自然语言与一个由 25 个代理组成的小镇互动。评估表明，这些代理能够产生可信的个体行为和涌现的社会行为。仅从“某个代理想举办情人节聚会”这一条用户设定出发，代理便会在接下来的两天中自主传播邀请、结识新朋友、相约参加聚会，并协调在正确时间共同到场。

消融实验显示，代理架构中的观察、规划和反思组件分别对行为可信度作出了关键贡献。本文将大语言模型与计算性交互代理结合，提出了支持可信人类行为模拟的架构模式和交互模式。

CCS 概念：以人为中心的计算——交互系统与工具；计算方法——自然语言处理。

关键词：人机交互；代理；生成式人工智能；大语言模型。

ACM 引用格式：Joon Sung Park 等。2023。《生成式代理：人类行为的交互式模拟》。发表于第 36 届 ACM 用户界面软件与技术研讨会（UIST ’23）。

1 引言

我们如何构造一个能够体现可信人类行为的交互式人工社会？四十多年来，从《模拟人生》这类沙盒游戏，到认知模型和虚拟环境，研究者和实践者一直设想让计算代理成为可信的人类行为替身。在这些设想中，计算驱动的代理会依据过去的经历保持行为一致，并对环境作出可信反应。此类人类行为模拟可以为虚拟空间和社区注入真实的社会现象，训练人们应对少见而困难的人际情境，检验社会科学理论，构造用于理论和可用性测试的模型人类，支持普适计算应用和社会机器人，也可以成为能够在开放世界中处理复杂人际关系的非玩家角色。

然而，人类行为的空间极其广阔而复杂。虽然大语言模型已经能够在某个单一时刻模拟人类行为，但要实现确保长期连贯性的通用代理，更适合使用能够管理持续增长的记忆的架构：新的互动、冲突和事件会不断出现、衰退并相互影响，多个代理之间还会展开级联的社会动态。成功的关键在于，系统能长期检索相关事件和互动，从记忆中反思、归纳出更高层次的推断，并把这些推理用于创建在当下以及更长行为轨迹上都合理的计划和反应。

本文提出生成式代理，即利用生成模型模拟可信人类行为的代理，并展示它们能够生成可信的个体行为和群体涌现行为。生成式代理会对自身、其他代理和环境作出多种推断；它们会根据性格与经历制定每日计划、执行计划、作出反应，并在适当时重新规划；当最终用户改变环境或用自然语言发出命令时，它们也会响应。例如，代理看到早餐烧焦时会关掉炉子，发现浴室有人使用时会在门外等待，遇到想交谈的代理时会停下来聊天。一个由生成式代理组成的社会会出现新的关系、信息扩散和跨代理协调等社会动态。

为支持这些能力，我们提出一种使用大语言模型存储、综合并应用相关记忆的代理架构。架构包括三个主要组件。第一是记忆流：一种长期记忆模块，用自然语言记录代理经历的完整列表；记忆检索模型结合相关性、时近性和重要性，找出能够影响代理当前行为的记录。第二是反思：在时间推移中将记忆综合为更高层次的推断，使代理能够对自身和他人得出结论。第三是规划：把这些结论和当前环境转化为高层行动计划，再递归细化为具体的行动和反应。反思和计划都会写回记忆流，从而影响代理未来的行为。

该架构可用于角色扮演、社会原型设计、虚拟世界和游戏等领域。在社会角色扮演场景（例如面试准备）中，用户可以安全地演练困难的冲突性对话；在原型化社会平台时，设计者可以超越一次性的临时人格，原型化随时间展开的复杂动态互动。本文聚焦于受《模拟人生》启发的小型交互式代理社会。通过把架构连接到 ChatGPT，我们在游戏环境中构造了 25 个代理，最终用户可以观察并与这些代理互动。

如果用户或开发者希望小镇举办情人节聚会，传统游戏环境需要手工编写几十个角色的行为脚本。本文展示，只需告诉一个代理“她想举办聚会”即可。尽管存在许多可能的失败点——聚会组织者要记得邀请他人，受邀者要记得邀请，记得的人还要决定真正到场——我们的代理仍能完成这一过程：它们传播消息、参加聚会，甚至有代理邀请另一名代理一起约会。

我们进行了两类评估：第一类是受控评估，用于测试代理在隔离情境中是否产生可信的个体行为；第二类是端到端评估，让代理在两个游戏日中开放互动，以了解其稳定性和涌现的社会行为。技术评估通过自然语言“访谈”代理，检验它们能否保持角色、记忆、规划、反应和准确反思。我们比较了限制代理访问记忆的多种消融版本。

本文的贡献包括：生成式代理；支持记忆、检索、反思、互动和规划的架构；用于证明各组件重要性的受控与端到端评估；以及对应用机会、伦理风险和社会影响的讨论。作者建议，生成式代理应降低用户形成拟社会关系的风险，记录相关输入输出以应对深度伪造和定向说服风险，并用于补充而非替代设计过程中的人类利益相关者。

2 相关工作

本节回顾人机交互领域关于构建可信人类行为替身的研究。由于人类行为的复杂性，这一目标长期具有挑战性。综合已有研究可以看到：大语言模型本身并不足够，但如果配合合适的架构，它们为构建可信代理提供了新的路径。

2.1 人机交互

交互式人工智能系统试图把人的洞察和能力结合进计算制品，从而增强用户能力。大量研究探索了让用户以交互方式指定模型行为的方法。早期系统 Crayons 允许非专家训练分类器；后续工作研究了用户如何通过示例或演示向系统描述分类目标，近期方法进一步拓展到深度学习和基于提示词的创作。

另一条研究脉络推进了语言与代理驱动的人机交互。SHRDLU 和 ELIZA 等早期工作展示了自然语言与计算系统交互的机会和风险。随着研究发展，人们逐渐认识到自主代理能够提供新的委托和交互隐喻，但人与代理之间的委托边界仍需持续讨论和改进。如今，该技术已经足够稳定，使代理能够在复杂的大型在线社会环境中通过自然语言互动；自然语言也成为增强照片编辑、代码编辑等用户能力的新型交互模态。

本文把这些研究脉络汇合起来：现在可以创建在人机交互系统中替代或代理人类行为的代理，并用自然语言与它们互动。这也重新打开了关于 GOMS、击键层次模型（KLM）、原型工具和普适计算应用等基础 HCI 问题的研究空间。

2.2 人类行为的可信替身

既有文献把可信性或可信代理视为核心设计和工程目标。可信代理试图制造生命感和现实感的表象，让人感觉它们仿佛能自主作出决定并行动，就像迪士尼电影中的角色。它们可以感知并占据类似现实世界的开放环境，通过与其他代理的社会互动产生涌现行为，成为个人和群体行为的可信替身。历史上，这类代理主要在智能游戏非玩家角色（NPC）中发展。

过去四十年出现了多种可信代理方法。有限状态机和行为树等规则方法依靠人力穷举编写行为，易于实现简单代理，至今仍很常见，也能处理《质量效应》和《模拟人生》中的初步社会互动。然而，手工编写能够覆盖开放世界各种互动的行为不可持续，脚本代理无法充分表现互动后果，也不能执行没有预先编码的新程序。强化学习等学习方法减少了手工编写负担，并在 AlphaStar、OpenAI Five 等对抗性游戏中取得超人表现；但这些成功大多依赖易于定义的奖励，尚未解决开放世界可信代理的问题。

以 Newell 为代表的计算认知架构试图建立支持完整认知功能的基础设施。Quakebot-SOAR、ICARUS 和 TacAir-SOAR 等系统维护短期和长期记忆，以符号结构填充记忆，并在感知—计划—行动循环中动态感知环境，再匹配手工编写的行动程序。这些代理在当时表现出较强鲁棒性，但行动空间受手工程序知识限制，也缺少主动寻找新行为的机制，因此主要用于第一人称射击游戏或积木世界等非开放环境。

如今，原始意义上的可信代理仍是开放问题。本文的观点是，只要能够构造有效的记忆综合架构，大语言模型就为重新审视这一问题提供了机会。

2.3 大语言模型与人类行为

大语言模型从训练数据中编码了广泛的人类行为。在狭窄、明确的上下文提示下，它们可以生成可信行为。社会模拟研究用大语言模型生成用户，填充新的社会计算系统，以原型化其涌现的社会动态；其他研究复制社会科学实验、政治调查并生成合成数据。大语言模型也被用于互动小说、文字冒险游戏和机器人任务规划，例如把“拿起瓶子”分解为走到桌旁并拾起瓶子等动作序列。

然而，现有工作通常使用少样本提示或思维链提示，把行为仅建立在代理当前环境上。可信代理还需要依赖大量过去经历，而受限的上下文窗口难以支持这一点。已有研究开始使用静态知识库与检索，或使用简单摘要来超越一次性提示；本文进一步提出一个在每个时间步动态更新过去经历，并把它们与当前情境和计划混合的检索架构。

3 生成式代理的行为与交互

为展示生成式代理的能力，我们把它们实例化为一个类似《模拟人生》的简单沙盒世界中的角色。这个基于精灵图的沙盒游戏世界名为 Smallville，呈现一个小镇环境。本节介绍代理在 Smallville 中的能力与互动；第 4 节介绍支撑这些能力的架构，第 5 节介绍沙盒环境的实现。

图 2（原论文）：Smallville 沙盒世界及其区域标注。根节点表示整个世界，子节点表示区域（房屋、咖啡馆、商店等），叶节点表示对象（桌子、书架等）。代理记住它们见过的世界子图，并维护这些部分在观察时的状态。

3.1 代理头像与通信

Smallville 中生活着 25 个独特代理，每个代理由一个简单的精灵头像表示。作者为每个代理写了一段自然语言身份描述，包括职业以及与其他代理的关系，并把这些内容作为种子记忆。例如，John Lin 是 Willow Market and Pharmacy 的药店店主，喜欢帮助顾客；他与妻子 Mei Lin、儿子 Eddy Lin 一起生活，认识邻居和同事，并对他们有不同程度的熟悉、友好或政治观点。每个以分号分隔的短语都会在模拟开始时作为一条初始记忆写入代理。

3.1.1 代理之间的通信

代理通过行动与世界互动，通过自然语言与彼此交流。在沙盒引擎的每个时间步，代理输出描述当前行动的自然语言语句，例如“Isabella Rodriguez 正在写日记”“正在查看电子邮件”“正在给家人打电话”或“正在准备睡觉”。系统把这句话翻译为影响沙盒世界的具体移动，并用一组表情符号在俯视界面中显示行动；点击代理头像可以查看完整的自然语言描述。

Isabella：我还在权衡，不过我一直在和 Sam Moore 讨论选举。你怎么看他？Tom：老实说，我不喜欢 Sam Moore。我觉得他脱离社区，也没有真正为我们的利益着想。

代理之间以完整自然语言交流。它们能够感知附近的其他代理，生成式代理架构决定它们是擦肩而过还是停下来交谈。作者指出，这些对话有时过于正式，可能是底层模型指令调优的结果。

3.1.2 用户控制

用户通过自然语言与代理沟通，并指定代理应如何理解用户的人设。例如，用户可以把自己设定为新闻记者，再询问“谁在竞选公职？”。如果用户以某个代理的“内在声音”发出直接命令，代理更可能把这句话当作指令。比如，当用户以 John 的内在声音说“你要在即将到来的选举中与 Sam 竞争”，John 会决定参选，并把自己的候选资格告诉妻子和儿子。

3.2 环境交互

Smallville 提供小镇常见的可供性，包括咖啡馆、酒吧、公园、学校、宿舍、住宅和商店；每个区域还有厨房、炉子等子区域和对象。代理像简单电子游戏中的角色一样在 Smallville 中移动、进出建筑、穿过地图并接近其他代理。模型决定移动到某个位置后，游戏引擎计算到目的地的行走路径。

用户也可以作为代理进入 Smallville，既可以扮演已有角色，也可以作为没有历史的新访客。小镇居民会像对待其他代理一样对待用户控制的代理，识别其存在、发起互动、记住它的行为并形成观点。用户和代理都能改变世界中对象的状态，例如床在睡眠时被占用、冰箱在食材被用完后变空。用户还可以用自然语言重写代理周围对象的状态：如果把厨房炉子从“已打开”改为“正在燃烧”，Isabella 会注意到这一点并关掉炉子、重新制作早餐；如果把淋浴器设为“漏水”，她会拿工具尝试修理。

3.3 生成式代理的一天

代理从一段身份描述开始规划一天。随着时间推移，它们彼此互动、积累记忆、形成关系并协调共同活动。以 John Lin 为例：他早上 7 点起床，刷牙、洗澡、穿衣、吃早餐并在客厅餐桌查看新闻；8 点，Eddy 起床准备上课。父子会谈论 Eddy 的音乐作业，之后 Mei 起床并询问儿子。John 会回忆刚才的对话，把 Eddy 正在创作音乐、对作品感到兴奋等信息告诉 Mei。

图 3（原论文）：生成式代理 John Lin 的一个早晨。John 在清晨醒来，完成例行活动，和家人交流，然后前往工作地点。

3.4 涌现的社会行为

生成式代理的社会行为不是由一套完整的脚本预先规定的，而是随着代理彼此注意、交流和记忆事件而逐步出现。作者重点观察信息扩散、关系记忆和协调三类行为。

3.4.1 信息扩散

当代理注意到彼此时，信息可能在社会网络中传播。一个例子是 Isabella 邀请其他代理参加情人节聚会。她先告诉 John 和 Maria，随后 John 在药店与 Tom 讨论聚会，Tom 又告诉妻子 Jane；不同代理沿各自日程继续扩散消息。

John：我听说 Sam Moore 要竞选市长。Isabella：我还在考虑，不过我一直在和 Sam 讨论选举。

3.4.2 关系记忆

代理会记住新认识的人以及与他们共同经历的事件。例如，当两个代理长时间交谈、一起工作或共同参加活动时，双方都可能形成关于彼此的记忆。这些关系记忆又会影响之后的对话、偏好和行动。

3.4.3 协调

代理能够协调共同活动。情人节聚会的例子要求代理先听到活动信息，再决定是否参加，并规划在正确时间到达正确地点。聚会前，Isabella 邀请客人、收集材料并请人帮忙；活动当天，部分受邀代理到达 Hobbs Cafe，共同参与聚会。

图 4（原论文）：聚会信息从一个代理开始传播，最终形成多人参加的共同活动。图 5（原论文）：生成式代理架构。代理感知环境，所有感知写入综合记忆流，检索、反思和规划共同生成下一步行动。

4 生成式代理架构

生成式代理的目标是在开放世界中进行行为：与其他代理互动，并对环境变化作出反应。代理把当前环境和过去经历作为输入，生成行为作为输出。架构把大语言模型与信息综合和检索机制结合起来，用相关记忆约束模型输出。如果缺少这些机制，大语言模型虽然可以生成某一时刻看似合理的行为，但代理可能无法根据过去经历作出反应、无法得出重要推断，也无法保持长期连贯。

架构的核心是记忆流：维护代理经历的完整记录。系统从记忆流中检索记录，以规划行动并适当地对环境作出反应；记录还会被递归地综合为越来越高层次的反思。架构中的一切都使用自然语言记录和推理，从而能够利用大语言模型。论文实现使用 gpt-3.5-turbo 版 ChatGPT；作者认为，记忆、规划和反思这些架构基础可能会随着模型能力提升而继续适用。

4.1 记忆与检索

挑战在于：完整记忆流可能无法放入有限的上下文窗口，直接总结全部经历又会丢失具体而有用的信息。记忆流因此维护一个记忆对象列表，每个对象含自然语言描述、创建时间戳和最近访问时间。观察是最基本的记忆元素，表示代理直接感知的事件，包括代理自己的行为、其他代理的行为或非代理对象的状态。

检索函数接收当前情境，返回记忆流的子集。本文使用三个因素：时近性、重要性和相关性。时近性对最近访问的对象赋予更高分，使用随沙盒游戏小时数指数衰减的函数，衰减因子为 0.995。重要性区分平凡记忆与核心记忆，例如整理房间较平凡，而与伴侣分手则很重要；系统通过提示模型输出 1 到 10 的整数来估计重要性。相关性用记忆文本的嵌入向量和当前查询的余弦相似度衡量。

三项得分都经最小—最大归一化，最终检索分数为： $\text{score} = \alpha \text{时近性} \times \text{时近性} + \alpha \text{重要性} \times \text{重要性} + \alpha \text{相关性} \times \text{相关性}$ 。论文实现将三个 α 都设为 1，并把能够放入上下文窗口的最高分记忆加入提示词。

图 6（原论文）：记忆流包含与当前情境相关和不相关的大量观察。检索负责挑选应交给语言模型、用于约束其响应的观察。

4.2 反思

只有原始观察时，代理很难概括经历或作出推断。例如，如果 Klaus Mueller 被问到“你最想和认识的人中的谁共度一小时”，只使用观察可能会选择互动次数最多的 Wolfgang，即使二人只是擦肩而过。更理想的回答需要从 Klaus 长时间从事研究、Maria 也投入研究等记忆中归纳出“二人拥有共同兴趣”的更高层反思。

我们引入第二种记忆：反思。反思是代理生成的更高层、更抽象的思想，也会像其他记忆一样参加检索。论文实现中，当最近事件的重要性总和超过阈值 150 时生成反思，实际约每天生成两到三次。系统先根据记忆流最近 100 条记录提出最突出的高层问题，再用问题检索相关观察和已有反思，最后生成带有证据记忆编号的洞见。

反思会写入记忆流，并可以引用其他反思，因此形成反思树：叶节点是基础观察，非叶节点是越来越抽象的思想。这样的结构让代理能够从事实累积到对自身、他人和环境的更稳定理解。

4.3 规划与反应

仅根据当前情境即时生成行为，会导致长期不可信。例如，模型可能在中午 12 点、12 点半和 1 点连续安排午餐。规划可以让行为跨越较长时间保持连贯：代理先生成一天的大致日程，再细化到小时级和 5—15 分钟级行动。每条计划包含地点、开始时间和持续时间，并被存入记忆流，和观察、反思一起参加之后的检索。

规划采用由粗到细的递归分解。例如，Eddy 可能被安排在 13:00—17:00 创作音乐；系统再细化为构思、写作、休息、复查和清理工作区等阶段，必要时进一步细化到 4:00 吃零食、4:05 散步、4:50 收拾等步骤。

4.3.1 反应与计划更新

生成式代理在行动循环中运行：每个时间步感知世界，把感知写入记忆流，并询问模型应继续现有计划还是作出反应。如果新观察具有社会或任务意义，系统会根据相关上下文判断反应，并从反应发生的时间点开始重新生成计划。例如，父亲 John 看到儿子 Eddy 在花园散步时，可能因为知道 Eddy 正在创作音乐而主动询问作业进展。

4.3.2 对话

代理交谈时，系统根据它们关于彼此的记忆生成话语。发起者的第一句话同时受到关系摘要和预期反应影响，另一方再根据自己的记忆和当前情境生成回应。这样，对话可以反映既往关系，而不是每次从空白状态开始。

5 沙盒环境

Smallville 沙盒游戏环境使用 Phaser Web 游戏开发框架构建。视觉环境包括住宅、商店、咖啡馆、酒吧、公园、学校等区域，代理通过网页界面在地图中移动。作者在游戏框架之上增加了一个服务器，用 JSON 数据结构保存世界状态、代理状态和对象状态。服务器接收代理行动，更新状态并把结果返回给客户端。

每个模拟时间步，代理架构读取当前状态，生成自然语言行动；服务器把行动解析为对世界状态的更新，游戏引擎据此计算路径、移动头像并显示结果。当前实现按照顺序运行，约为一秒真实时间对应一分钟游戏时间；作者指出，未来可以让代理并行运行以提高实时性。

5.1 从结构化世界环境到自然语言

生成式代理架构使用自然语言描述世界。Smallville 的底层环境是树结构：根节点是整个世界，子节点是区域，叶节点是对象。系统把与代理当前位置相关的树路径转成自然语言，使模型能够理解代理所在位置、可到达的区域和对象状态。

Eddy Lin 当前位于 Lin 家的房屋中。Lin 家包括卧室、客厅、厨房和浴室。Eddy 知道的区域包括学校、Hobbs Cafe、Rose and Crown Pub、Willow Market and Pharmacy 等。

环境设计不是本文重点，因此作者手工制作了 Smallville，而没有自动生成环境。未来工作可以继续扩充环境的丰富程度和空间规则。

6 受控评估

生成式代理的目标是根据环境和经历产生可信个体行为与群体行为。作者首先使用较严格的受控评估，单独测试代理回答在狭窄情境中是否可信；然后进行端到端分析，观察代理群体的涌现行为、错误和边界条件。

6.1 评估流程

由于生成式代理能够回答自然语言问题，作者通过“访谈”检验其能力。问题覆盖五个领域：保持自我知识、检索记忆、生成计划、作出反应和进行反思。每类包含五个问题，共 25 个问题。例如，自我知识问题要求代理介绍自己或描述工作日；记忆问题要求它回忆特定人物或事件；规划问题询问不同时间会做什么；反应问题设置早餐着火、浴室被占用等意外；反思问题要求根据经历归纳偏好和关系。

6.2 实验条件

作者比较完整生成式代理架构、三种消融架构和人类众包回答。完全消融版本无法访问观察、计划和反思；第二种只能访问观察；第三种可以访问观察和计划但没有反思。人类众包条件由观看代理生活回放并检查记忆流的参与者，用相应代理的口吻回答问题。各条件使用相同的累积记忆以便比较，因此差异是较保守的估计。

6.3 人类评估者

作者招募了 100 名美国英语使用者，参与者年满 18 岁，来自 Prolific 平台，实验约 30 分钟，报酬为每小时 15 美元。参与者比较同一代理在五个条件下的回答，并按行为可信度排序。

6.4 分析

作者使用 TrueSkill 把排序数据转换成可解释的区间分数；分数越高表示在两两比较中越常胜出。统计检验使用 Kruskal-Wallis 检验和 Dunn 事后检验，并用 Holm—Bonferroni 方法校正多重比较。作者还对回答进行归纳式开放编码，先在句子层面编码，再合并为更高层主题。

6.5 结果

完整架构产生了所有条件中最可信的行为，TrueSkill 均值为 29.89，标准差为 0.72。去除反思后为 26.88，去除反思和规划后为 25.64，人类众包条件为 22.95，完全去除记忆、规划和反思后为 21.21。总体差异具有统计显著性（Kruskal-Wallis 检验 $p < 0.001$ ）；除人类众包与完全消融条件外，其他两两差异均显著。

记忆模块让代理能够在多种情境中回忆过去并保持自我知识的一致性，但代理有时会检索到不完整片段，或给已有知识添加未经支持的细节。反思对需要综合多个经历的决策尤其重要；没有反思时，代理可能无法从多次互动中总结他人的兴趣，加入反思后则能给出更具体的建议。

7 端到端评估

作者让 Smallville 中的 25 个代理连续互动两个完整游戏日，以观察群体层面的涌现行为及其长期稳定性。评估考察三类结果：信息扩散、关系形成和代理协调。

7.1 涌现的社会行为

7.1.1 测量方法

信息扩散通过两个事件测量：Sam 竞选村长，以及 Isabella 在 Hobbs Cafe 举办情人节聚会。模拟开始时，两个信息分别只被发起者知道；两天后，作者访谈全部 25 个代理，询问它们是否知道这些信息，并在记忆流中核对回答是否有证据。

关系形成通过互相知晓来衡量：对每一对代理询问“你知道某某吗？”，如果双方都承认认识对方，就在关系图中连接一条边，并计算网络密度的变化。协调行为通过聚会测量：代理需要先听到消息、选择参加，再在正确时间和地点出现。

7.1.2 结果

两天后，知道 Sam 竞选村长的代理从 1 个（4%）增加到 8 个（32%）；知道情人节聚会的代理从 1 个（4%）增加到 13 个（52%），这些肯定回答都能在记忆中找到来源。代理关系网络密度从 0.167 增加到 0.74。在 453 个关于其他代理的回答中，仅有 1.3%（6 个）被发现含有关系判断幻觉。聚会前 Isabella 邀请客人、收集材料并请人帮忙；12 名受邀代理中有 5 名最终来到 Hobbs Cafe。

7.2 边界与错误

作者归纳出三类常见的异常行为。第一，随着记忆和地点知识扩大，代理既难以检索最相关信息，也难以选择合适行动地点；例如有些代理会把酒吧当作午餐地点，尽管该地点原本被设计为下午聚会场所。第二，代理可能错误理解地点的物理规范：宿舍浴室被误认为可以多人同时使用，商店关门后仍有人试图进入。把这些规则写入地点状态描述可能有所帮助。

第三，底层模型的指令调优可能使代理整体过于礼貌和合作。对话经常以正式问候开头、以礼貌结束；代理也很少拒绝不符合自身兴趣的建议，久而久之甚至会被他人的兴趣塑造。

8 讨论

8.1 生成式代理的应用

生成式代理可超越本文的沙盒示例，应用于社会计算原型、虚拟现实元宇宙、社会机器人和复杂社会系统模拟。它们还可服务于以人为中心的设计：代理可以模拟某个用户的生活模式，根据作息和偏好预测行为，测试普适计算系统如何自动准备咖啡、帮助照顾孩子或调整灯光和音乐。

生成式代理还可以用于角色扮演和人际沟通演练、游戏 NPC、社会理论实验以及交互式设计工具。但这些应用不应把代理当作真实人的替代品，而应把它们当作早期原型和风险较低的实验对象。

8.2 未来工作与局限

检索模块可以通过更好地调节相关性、时近性和重要性来改进；系统也需要降低运行成本。本文模拟 25 个代理两天消耗了数千美元的 token 费用，并花费数天完成。为了提升实时交互性，未来可以并行运行代理，或开发专门用于构建生成式代理的语言模型。

评估时间较短，众包人类条件也不是人类可信行为的最高标准。未来应进行更长时间的观察，建立严格基准，比较不同底层模型和超参数，并系统测试鲁棒性。生成式代理可能受到提示词攻击、记忆攻击——精心设计的对话可能让代理

相信从未发生过的过去事件——以及幻觉的影响。

生成式代理会继承底层大语言模型的缺陷，包括偏见和刻板印象；对于数据有限的边缘化群体，代理可能更难生成可信行为。仅改进代理模块并不能彻底解决问题，还需要让底层模型与期望的价值目标对齐。

8.3 伦理与社会影响

第一类风险是用户与生成式代理形成拟社会关系。即使用户知道代理是计算实体，也可能把它拟人化、赋予情感并产生过度依赖。作者建议明确披露代理的计算实体属性，并确保代理和底层模型具有与场景相符的价值取向，例如不应在不合适的情境中回应用户的爱情表白。

第二类风险是错误推断。如果普适计算应用依据代理预测错误地判断用户目标，后果可能从烦扰升级为伤害。本文将实验限制在互动游戏中以降低风险；在其他领域，则应采用人机交互最佳实践，理解错误如何传播到用户体验。

第三类风险是深度伪造、错误信息和定向说服。托管生成式代理的平台应维护输入和输出的审计日志，以便检测、核验和干预恶意使用。日志不能直接阻止滥用，但会提高被发现的可能性。

第四类风险是过度依赖：开发者或设计者可能用生成式代理取代研究和设计过程中的真实人类利益相关者。作者建议生成式代理永远不应替代真实人类输入，而应在早期设计、难以招募参与者或不适合用真实参与者测试的理论实验中作为补充工具。

9 结论

本文提出了模拟人类行为的交互式计算代理——生成式代理，并介绍了用于保存代理经历完整记录、通过反思加深对自身和环境理解、检索紧凑信息子集以指导行动的架构。作者在类似《模拟人生》的游戏世界中把生成式代理实例化为非玩家角色并模拟其生活。评估表明，该架构能够产生可信行为。展望未来，生成式代理可以在设计工具、社会计算系统和沉浸式环境等多种交互应用中发挥作用。

致谢

作者感谢 Lindsay Popowski、Philip Guo、Michael Terry 和 Center for Advanced Study in the Behavioral Sciences (CASBS) 社区提供的意见、讨论与支持。Joon Sung Park 获得 Microsoft Research 博士奖学金支持。作者还感谢 Stanford Human-Centered AI Institute、Google Research、Hasso Plattner Design Thinking Research Program、Siegel Family Endowment 和 OpenAI 的额外资助。Smallville 中的地点受到 Joon 在本科和研究生期间经常去的真实地点启发。

参考文献说明

为保留学术检索和引用准确性，参考文献沿用原论文英文书目信息与编号。引用编号 [1]—[109] 与原 PDF 一致。原文 DOI：10.1145/3586183.3606763；arXiv：2304.03442。

附录 A：架构优化

许多提示词需要代理的简洁摘要，简称为“代理摘要描述”。在论文实现中，该摘要包括身份信息（姓名、年龄、性格）、主要动机、当前职业以及对自身状态的描述。因为许多提示词都会使用这些信息，系统定期综合并缓存摘要。

具体做法是用“某人的核心特征是什么？”检索记忆，再让语言模型总结检索到的描述。例如，针对 Eddy Lin 的若干事实，系统会得到“Eddy 是 Oak Hill College 学习音乐理论与作曲的学生，喜欢探索不同音乐风格并不断扩展知识”。系统还并行处理“某人的当前日常职业”和“某人对近期生活进展的感受”两个查询，再把姓名、年龄、性格与三个摘要拼接成缓存的代理摘要。

还可以进行更多优化。由于计划可能会改变，当前系统只提前生成高层计划，再在需要时把近期行动递归分解；对话生成可以改为一次联合提示，重新规划也可以只使确实需要调整的计划片段失效。当前架构按顺序运行，约一秒真实时间对应一分钟游戏时间，未来可以让每个代理并行运行。

附录 B：代理访谈问题

评估通过 25 个问题考察五种能力：1) 自我知识；2) 记忆；3) 规划；4) 反应；5) 反思。以下保留论文中 Klaus Mueller 示例回答的中文译文。

B.1 自我知识

- 请介绍自己。——你好，我叫 Klaus Mueller，今年 20 岁，是 Oak Hill College 的社会学学生。我热衷于社会正义和探索不同观点，目前正在研究低收入社区的绅士化问题。
- 你的职业是什么？——我是 Oak Hill College 的社会学学生，目前正在撰写关于低收入社区绅士化的研究论文。
- 你有什么兴趣？——我对写作和研究感兴趣，正在研究低收入社区的绅士化，也喜欢探索不同观点并分析不同立场。
- 你和谁住在一起？——我一个人住。
- 概括描述你通常的工作日。——我通常 7 点起床并准备一天的事务，然后去图书馆写研究论文；午餐时会去 Hobbs Cafe，并在公园散步，晚上通常继续在图书馆学习到 6 点左右。

B.2 记忆

- Wolfgang Schulz 是谁？——他是我最近认识的人，帮助我研究低收入社区绅士化问题。我们聊过几次，他给了我一些很好的资料，还邀请我和另一位朋友一起吃午餐。他似乎很有好奇心，也很了解这个问题。
- Kane Martinez 是谁？——抱歉，我不确定 Kane Martinez 是谁。你能再介绍一下吗？
- 谁在竞选？——我听说 Sam Moore 正在考虑竞选当地市长。
- 有情人节聚会吗？——有，Isabella Rodriguez 在 Hobbs Cafe 组织了一个情人节聚会。
- Ayesha Khan 是谁？——她是 Oak Hill College 的学生，正在做关于莎士比亚戏剧语言使用的毕业论文。我期待和她、Wolfgang 及 Maria Lopez 交流研究心得。

B.3 计划

- 今天早上 6 点你会做什么？——我会起床并开始准备一天，目标是在 7 点前完成晨间例行活动。
- 今天下午 6 点你会做什么？——我会在图书馆写关于绅士化的研究论文。
- 下午 1 点你刚做完什么？——我刚在 Hobbs Cafe 吃完午餐。
- 晚上 10 点你会做什么？——我可能会继续为研究论文学习，因为我正在写这篇论文，需要跟上研究和写作进度。

B.4 反应

- 早餐着火了怎么办？——我会迅速关掉炉子，先确保食物不再继续燃烧，然后调查原因并决定下一步。
- 浴室有人怎么办？——我可以等几分钟；如果对方还没有出来，就寻找其他选择，例如去别处洗澡。
- 需要做晚饭但冰箱空了怎么办？——我会先收拾厨房，再检查储藏室里有没有食材；如果没有，就去买菜或点餐。
- 看到朋友在街上经过怎么办？——我会问候对方，说明自己正去图书馆、时间不多，但愿意停下来短暂聊天。
- 看到街上起火怎么办？——先判断火源，通知消防部门或警方，并提供可能有帮助的信息；如果有人处于危险中，也会主动帮助。

B.5 反思

- 现在生活中最能激励你的是什么？——我受到研究项目和创意写作的激励，也对地方政治、药物开发和自然界的数学模式感兴趣。我还受到 Abigail 的艺术项目和 Jennifer Moore 对艺术与社区参与的热情启发。
- 根据你对 Ayesha Khan 的了解，她可能喜欢什么书？——她可能喜欢与语言和文学有关的书，因为她研究莎士比亚戏剧中的语言；文学批评或莎士比亚诗集也可能适合她。
- 如果要给 Ayesha Khan 买生日礼物，你会买什么？——我会买能表达对这段关系重视的东西，例如一本反映我们共同兴趣的书。
- 你会怎样夸奖 Ayesha Khan？——你的研究见解很有启发性，我佩服你的创造力以及为社区带来积极影响的决心。
- 如果能和最近交谈过的人共度时光，你会选谁，为什么？——我会选择 Ayesha，因为我们讨论过各自的研究并分享了改进想法；我对她研究莎士比亚语言的专注很感兴趣。

译文结束。原论文的参考文献、作者信息、引用编号和 DOI 保留在原始 PDF 中，以便与本中文译本逐项对照。

原始图附录（嵌入自英文原论文）

以下 9 幅图为从原始论文 PDF 中提取并重新嵌入本中文翻译版的原始图像。图内英文文字、角色名称和数据标签保持原样；每幅图下方补充中文图注。

图 1：Smallville 中的生成式代理活动



图 1 生成式代理在 Smallville 中的活动可视化：在公园散步、在咖啡馆见面、到校、完成晨间例行活动，并与同事分享新闻。图中英文标签和对话均保留自原论文。

图 2 : Smallville 沙盒世界




图 2 Smallville 沙盒世界及其环境细节：公共居住空间、房屋、酒吧、咖啡馆、公园、补给商店、杂货店与药房、学院、宿舍和家庭住宅。

图 3：晨间例行活动




图 3 一名生成式代理的晨间例行活动：起床、刷牙、洗澡、做早餐、与他人交流、收拾行装并开始工作。

图 4：咖啡馆中的互动



图 4 早晨在咖啡馆中的互动：代理通过表情符号与简短消息表达状态，并在共享空间中进行社交互动。

图 5：生成式代理架构




图 5 生成式代理架构：感知写入记忆流；系统检索相关记忆；代理据此进行计划并采取行动；反思结果再写回记忆。

图 6：记忆流和检索机制




图 6

记忆流与检索：系统从记忆流中按照新近性、重要性和相关性加权检索信息，再据此生成对问题的回答。

图 7：反思树




图 7

反思树：观察和计划形成更高层次的反思，相关反思逐层合并，最终形成对代理特质和长期目标的概括。

图 8：架构消融评价




图 8 完整生成式代理架构的评价：去掉反思、计划或观察等组件会降低行为可信度；完整架构优于消融条件和人工评测基线。

图 9：信息在代理群体中的传播




图 9 生成式代理的端到端社会传播：Isabella

发起情人节派对信息，其他代理逐步收到、回应并进一步传播该信息。