

生成式代理：人类行为的交互式模拟

Generative Agents: Interactive Simulacra of Human Behavior

Joon Sung Park

Stanford University

Stanford, USA

joonspk@stanford.edu

Joseph C. O'Brien

Stanford University

Stanford, USA

jobrien3@stanford.edu

Carrie J. Cai

Google Research

Mountain View, CA, USA

cjcai@google.com

Meredith Ringel Morris

Google DeepMind

Seattle, WA, USA

merrie@google.com

Percy Liang

Stanford University

Stanford, USA

pliang@cs.stanford.edu

Michael S. Bernstein

Stanford University

Stanford, USA

msb@cs.stanford.edu

arXiv:2304.03442v2 [cs.HC], 2023 年 8 月 6 日



图 1：生成式代理是用于交互应用的、可信的人类行为拟像。在本研究中，我们通过在一个令人联想到 The Sims 的沙盒环境中放入 25 个代理，展示生成式代理。用户可以观察并介入代理安排每日计划、分享消息、建立关系和协调群体活动的过程。

摘要

可信的人类行为替身能够为交互应用提供支持，其应用范围涵盖沉浸式环境、人际沟通的演练空间以及原型设计工具。本文介绍生成式代理：能够模拟可信人类行为的计算机软件代理。生成式代理会起床、做早餐并出门工作；艺术家绘画，作家写作；它们形成看法、注意到彼此并发起交谈；它们在规

划第二天时，会记住并反思过去的日子。为实现生成式代理，我们描述了一种扩展大语言模型的架构：使用自然语言存储代理经历的完整记录，随着时间推移将这些记忆综合为更高层次的反思，并动态检索它们以规划行为。我们将生成式代理实例化，放入一个受 The Sims 启发的交互式沙盒环境中，终端用户可以使用自然语言与一个由 25 个代理组成的小镇互动。在评估中，这些生成式代理产生了可信的个体行为以及涌现的社会行为。例如，起

初用户只指定了一个想法，即某个代理希望举办情人节聚会，代理们便在接下来的两天里自主传播聚会邀请、结识新朋友、邀请彼此作为约会对象参加聚会，并协调在合适的时间一起到场。通过消融实验，我们证明，代理架构的各个组件——观察、规划和反思——都对代理行为的可信度作出了关键贡献。通过融合大语言模型与计算式交互代理，本研究提出了用于实现可信人类行为模拟的架构模式和交互模式。

CCS 概念

• 以人为中心的计算 → 交互系统与工具；• 计算方法论 → 自然语言处理。

关键词

人类与 AI 交互，代理，生成式 AI，大语言模型

ACM 引用格式：

Joon Sung Park, Joseph C. O'Brien, Carrie J. Cai, Meredith Ringel Morris, Percy Liang, and Michael S. Bernstein. 2023. Generative Agents: Interactive Simulacra of Human Behavior. In *The 36th Annual ACM Symposium on User Interface Software and Technology (UIST '23)*, October 29–November 1, 2023, San Francisco, CA, USA. ACM, New York, NY, USA, 22 pages. <https://doi.org/10.1145/3586183.3606763>

允许出于个人或课堂用途，免费制作本作品部分或全部内容的数字副本或纸质副本，前提是这些副本不得用于营利或商业利益的制作或分发，且副本首页须载明本声明和完整引用。本作品中第三方组件的版权必须得到尊重。如需用于任何其他用途，请联系版权所有人 / 作者。

UIST '23, 2023 年 10 月 29 日至 11 月 1 日, San Francisco, CA, USA

© 2023, 版权由版权所有人 / 作者持有。

ACM ISBN 979-8-4007-0132-0/23/10.

<https://doi.org/10.1145/3586183.3606763>

1 引言

我们如何构建一个能够呈现可信人类行为的交互式人工社会？从 *The Sims* 这样的沙盒游戏，到认知模型 [23] 和虚拟环境 [10, 59] 这样的应用，40 多年来，研究人员与实践者一直设想能够充当可信人类行为替身的计算代理。在这些设想中，由计算驱动的代理会按照其过去的经历一致地行动，并对环境作出可信的反应。这类人类行为模拟可以在虚拟空间和社区中形成逼真的社会现象 [27, 80]，训练人们如何

处理罕见而棘手的人际情境 [44, 52, 94]，检验社会科学理论 [12, 46]，构建用于理论检验和可用性测试的人类处理器模型 [23, 39, 51]，支持普适计算应用 [31] 和社交机器人 [10, 14]，并为能够在开放世界中应对复杂人际关系的非玩家游戏角色 [59, 85] 提供基础。

然而，人类行为的空间广阔而复杂 [85, 108]。尽管能够模拟单一时间点上人类行为 [39, 80] 的大语言模型 [18] 已取得显著进展，要使完全通用的代理保持长期一致性，更合适的架构应当能够在新的交互、冲突和事件随时间出现与消退时管理不断增长的记忆，同时处理多个代理之间展开的连锁社会动态。要取得成功，就需要一种方法，能够检索长时间跨度内的相关事件与交互，通过反思这些记忆进行概括并作出更高层次的推断，再运用这种推理制定计划和反应，使其既在当下合理，也与代理行为的长期发展脉络相符。

本文介绍生成式代理——借助生成式模型来模拟可信人类行为的代理——并展示它们能够产生可信的个体行为拟像，以及涌现的群体行为拟像。生成式代理会对自身、其他代理及其环境作出各种推断；它们制定反映自身特征与经历的每日计划，执行这些计划，作出反应，并在适当时重新规划；当终端用户改变其环境，或以自然语言对其发出指令时，它们会作出回应。例如，生成式代理看到早餐烧焦时会关掉炉灶，卫生间被占用时会在门外等待，遇到想与之交谈的其他代理时会停下来聊天。¹ 一个充满生成式代理的社会呈现出涌现的社会动态：新的关系得以形成，信息得以传播，代理之间开始出现协调。

为实现生成式代理，我们描述了一种代理架构，通过存储、综合和应用相关记忆，使用大语言模型生成可信的行为。我们的架构包含三个主要组件。第一个是记忆流，即一个长期记忆模块，用自然语言全面记录代理的各项经历。记忆检索模型综合相关性、时近性与重要性，找出为代理每时每刻的行为提供依据所需的记录。第二个是反思，它随着时间推移将记忆综合为更高层次的推断，使代理能够得出有关自身和他人的结论，更好地指导其行为。第三个是规划，它将这些结论与当前环境转化为高层次的行动计划，再递归转化为执行行动和作出反应的详细行为。这些反思和计划会反馈至记忆流，影响代理今后的行为。

这一架构显示出在多个领域中的应用可能性，包括角色扮演、社交原型设计、虚拟世界和游戏。在社交角色扮演情境中（例如面试准备），用户可以安全地演练困难且充满冲突的对话。在为社交平台设计原型时，设计师可以超越临时的人物画像，对随时间展开的动态而复杂的交互进行原型设计。在本文中，我们重点关注创建一个小型交互式代理社会的能力，其灵感来自 The Sims 等游戏。²

通过将我们的架构连接到 ChatGPT 大语言模型 [77]，我们在一个游戏环境中实现了由 25 个代理组成的社会。终端用户可以观察这些代理并与其互动。例如，如果终端用户或开发者希望小镇在游戏内举办情人节聚会，传统游戏环境就需要人工为数十个角色的行为编写脚本。我们证明，使用生成式代理时，只需告诉一个代理她想举办聚会就足够了。尽管存在许多潜在的失败环节——聚会筹办者必须记得邀请其他代理参加聚会，参加者必须记得这份邀请，记住邀请的人还必须决定真正到场，等等——我们的代理仍然成功了。它们传播聚会的消息，然后前来参加，其中一个代理甚至邀请另一个代理作为约会对象一同参加聚会，这一切都源于用户提出的一个初始建议。

1 在提及生成式代理采取行动或前往某处时，这只是为了便于阅读而使用的简略表述，并不意味着它们具备类似人类的能动性。我们代理的行为与 Disney 动画角色相似，旨在营造可信的感觉，但并不意味着真正的能动性。

2 生成式代理社会的实际模拟演示可通过以下链接观看：https://reverie.herokuapp.com/UIST_Demo/。模拟代码的公共仓库位于：https://github.com/joonspk-research/generative_agents

我们对生成式代理进行了两项评估：一项受控评估，用于检验代理能否在独立情况下产生可信的个体行为；另一项端到端评估，让代理在两个游戏日内以开放的方式相互互动，以了解它们的稳定性和涌现的社会行为。在技术评估中，我们利用了一个方法论上的机会，通过以自然语言“访谈”代理来评估其知识与行为，探查代理准确保持角色设定、记忆、规划、反应和反思的能力。我们比较了多种消融设置，限制代理使用记忆、反思和规划。我们观察到，这些组件中的每一个都对代理在这些访谈任务中取得良好表现至关重要。在技术评估和端到端评估中，最常见的错误发生在代理未能检索到相关

记忆、为代理的记忆虚构润饰细节，或继承了语言模型过于正式的言语或行为之时。

总体而言，本文作出以下贡献：

- 生成式代理：可信的人类行为拟像，其行为动态地以代理不断变化的经历和环境为条件。
- 一种新的架构，使生成式代理能够在动态演变的情境中记忆、检索、反思、与其他代理互动并进行规划。这一架构利用大语言模型强大的提示能力，并补充这些能力，以支持代理在更长时间内保持一致性、管理动态演变的记忆，以及递归地产生更高层次的反思。
- 两项评估，即受控评估和端到端评估，通过因果效应确立各架构组件的重要性，同时识别由记忆检索不当等问题引发的失效情况。
- 讨论生成式代理在交互系统中的机遇，以及伦理与社会风险。我们认为，应对这些代理进行调整，以降低用户形成准社会关系的风险；记录它们的活动，以降低深度伪造和定制化说服所带来的风险；并在设计过程中补充而非取代人类利益相关者的方式使用它们。

2 相关工作

本节回顾人类与 AI 交互领域的既有文献，并将构建可信人类行为替身这一研究议程置于其经典研究脉络之中。这一议程曾被交互、游戏和人工智能研究群体视为指路明灯 [10, 59, 85, 86]，却因人类行为的复杂性而始终充满挑战 [17, 108]。我们综合这些研究，提出大语言模型虽然自身尚不足以完成这一任务，但若通过适当的架构加以运用，就能为创建可信代理开辟新的视角。

2.1 人类与 AI 交互

交互式人工智能系统旨在将人类的洞察与能力融入计算制品，以增强用户的能力 [4, 30]。长期以来，一系列研究一直在探索如何让用户以交互方式指定模型的行为。例如，Crayons 展现了交互式机器学习的早期愿景，让非专业用户能够训练分类器 [30]。后续研究进一步阐明了终端用户如何通过示例 [34] 或演示 [32] 向系统描述其分类目标。近期的进展已将这

些探索扩展至深度学习 [63] 和基于提示的创作 [50, 67, 106]。

与此同时,一条持续的研究路线一直在人机交互中推动基于语言和代理的交互。SHRDLU [103] 和 ELIZA [102] 等奠基性工作展现了使用自然语言与计算系统交互所带来的机遇与风险。随着研究推进,自主代理能够为委托与交互提供新隐喻 [68] 这一点日益清晰,但人类与代理之间的委托边界仍是持续争论和改进的对象 [47, 89, 90]。近来,这一技术已达到一定的稳定程度,使代理能够在大型而复杂的在线社会环境中通过自然语言互动(例如 [55])。自然语言交互提供了一种新的交互模态,可以增强用户在照片编辑 [3, 35, 65] 和代码编辑 [88] 等领域的能力。

我们汇集这些研究路线,表明如今可以为交互系统创建代替人类行为的代理,并使用自然语言与其互动。由此,本研究重新打开了探索基础性人机交互问题的大门,这些问题围绕 GOMS 和击键层次模型 (Keystroke-Level Model, KLM) [22, 23] 等认知模型、原型设计工具 [80],以及普适计算应用 [26, 31, 101] 展开。

2.2 可信的人类行为替身

既有文献将可信度,或可信代理,描述为核心的设计与工程目标。可信代理旨在营造生命的幻觉,并通过看似自行作出决定、出于自身意愿采取行动的方式,呈现逼真的表象,类似于 Disney 电影中的角色 [10, 96]。这些代理可以置身于并感知一个与我们所处世界相似的开放世界环境 [10, 59],并努力表现出以与用户或其他代理的社会交互为基础的涌现行为,目标是在关于个体和社区的假想模拟中,成为我们行为的可信替身 [20, 36, 71]。从历史上看,这些代理是在智能游戏非玩家角色 (NPC) 的背景下发展起来的 [59, 85]。如果能够创建行为可信的 NPC,就可以通过支持涌现叙事 [8, 16, 49, 93] 以及与代理的社会交互 [109],提升玩家在游戏和交互式小说中的体验。然而,更重要的是,游戏世界对现实世界可供性的呈现日益逼真;正如 Laird 和 van Lent 在 2001 年所指出的,这些模拟世界为可信代理的开发者提供了易于使用的试验平台,让他们能够完善代理的认知能力,而不必担心如何在现实世界中实现机器人系统,或从头构建模拟环境 [59, 85]。

在过去 40 年里,出现了多种创建可信代理的方法。然而,在实施过程中,这些方法往往简化环境或缩减代理行为的维度,以使这项工作更易于处理 [17, 73]。有限状态机 [91, 97] 和行为树 [41, 54, 82] 等基于规则的方法,体现了由人类直接编写代理行为的蛮力方法 [71]。它们提供了创建简单代理的直接方式,至今仍是最占主导地位的方法 [69, 74, 108],而且甚至可以处理初级的社会交互,Mass Effect [13] 和 The Sims [7] 等游戏系列就展示了这一点。然而,人工构建能够全面应对开放世界中各种可能交互的行为,是难以为继的。这意味着生成的代理行为可能无法充分体现其交互的后果 [70–72],也无法执行未在脚本中硬编码的新程序 [91, 97]。另一方面,强化学习等创建可信代理的常见学习方法,通过让代理学习其行为,克服了人工编写的难题,近年来在一些游戏中取得了超越人类的表现,例如用于 Starcraft 的 AlphaStar [99] 和用于 Dota 2 的 OpenAI Five [11]。然而,它们的成功主要发生在对抗性游戏中,这类游戏具有容易定义、可供学习算法优化的奖励。它们尚未解决在开放世界中创建可信代理的挑战 [40, 74, 91]。

由 Newell 开创的计算认知架构,旨在构建支持全面认知功能 [76] 的基础设施,以契合可信代理最初愿景中包罗万象的特性。它们推动了一些最早的可信代理实例。例如,Quakebot-SOAR [60] 和 ICARUS [25, 64] 在第一人称射击游戏中生成 NPC,而 TacAir-SOAR [81] 在空战训练模拟中生成飞行员。这些代理所使用的架构有所不同(Quakebot-SOAR 和 TacAir-SOAR 依赖 SOAR [61],而 ICARUS 依赖其自身的一种变体,灵感来自 SOAR 和 ACT-R [6]),但它们具有相同的底层原则 [62]。它们维持短期与长期记忆,以符号结构填充这些记忆,并按照“感知—规划—行动”的循环运行,动态地感知环境,并将其与人工编写的某个行动程序匹配 [58, 97]。使用认知架构创建的代理,旨在能够泛化到大多数乃至所有开放世界情境,在当时表现出了稳健的行为。然而,它们的行动空间受限于人工编写的程序性知识,也没有提供能够启发代理寻求新行为的机制。因此,这些代理大多部署在第一人称射击游戏 [25, 60] 或积木世界 [64] 等非开放世界情境中。

如今,创建符合最初定义的可信代理仍是一个尚未解决的问题 [85, 108]。许多人已转向其他方向,认为

尽管目前创建可信代理的方法可能繁琐且受限，但已经足以支持现有的游戏玩法和交互 [24, 75, 108]。我们的观点是，只要能够构建有效的架构，将记忆综合为可信行为，大语言模型就提供了重新审视这些问题的机会。本文朝这样的架构迈出了一步。

2.3 大语言模型与人类行为

生成式代理使用大语言模型来驱动其行为。关键的观察在于，大语言模型从训练数据中编码了广泛的人类行为 [15, 18]。如果用一个界定狭窄的情境作为提示，这些模型就可以用于生成可信的行为。近期工作已证明这一方法的有效性。例如，社会拟像研究使用大语言模型生成用户，填充新的社会计算系统，以便对其涌现的社会动态进行原型设计 [80]。这一方法使用提示链 [105, 106]，生成关于人物画像及其在待设计原型的系统中所表现行为的简短自然语言描述。其他实证研究复现了已有的社会科学研究 [46]、政治调查 [92]，并生成了合成数据 [39]。大语言模型也被用于生成可供用户互动的人类行为。例如，在游戏中，这些模型被用于创建交互式小说 [37] 和文字冒险游戏 [21]。大语言模型能够生成并分解行动序列，因此也被用于规划机器人任务 [48]。例如，当面对拿起一个瓶子这样的任务时，模型会收到提示，将该任务分解为更小的行动序列，例如走向放着瓶子的桌子，再将瓶子拿起。

基于上述工作，我们提出，大语言模型可以成为创建可信代理的关键要素。既有文献主要依赖一种可被视为一阶模板的方法，使用少样本提示 [38, 66] 或思维链提示 [100]。这些模板能够有效地生成仅以代理当前环境为条件的行为（例如，网络挑衅者会如何回应某条帖子，或者已知有一扇门时，机器人需要采取哪些行动才能进入一个房间）。然而，可信代理不仅需要以当前环境为条件，还需要以大量过往经历为条件；使用一阶提示并不适合这一要求（而且截至目前，由于底层模型的上下文窗口有限，这一点还无法实现）。近期研究尝试通过静态知识库和信息检索方案 [53]，或简单的摘要方案 [104] 来增强语言模型，从而超越一阶提示。本文扩展了这些思路，构建一种能够处理检索的代理架构：过往经历在每个时间步动态更新，并与代理当前的情境和计划混合，而这些内容可能相互强化，也可能彼此矛盾。

3 生成式代理的行为与交互

为说明生成式代理的可供性，我们将其实例化为一个令人联想到 The Sims [7] 的简单沙盒世界中的角色。这个以精灵图为基础的沙盒游戏世界名为 Smallville，呈现了一个小镇环境。本节将逐一介绍 Smallville 中生成式代理的可供性及其交互的方式，并描述代理在其中如何行动。随后，我们将在第 4 节介绍支持这些可供性和交互的生成式代理架构。在第 5 节，我们将描述沙盒环境的实现，以及代理如何与沙盒世界的底层引擎交互。




图 2: 标注了各区域的 Smallville 沙盒世界。根节点描述整个世界, 子节点描述区域 (例如住宅、咖啡馆、商店), 叶节点描述物体 (例如桌子、书架)。代理记住一个子图, 反映它们已看到的世界部分, 并维持这些部分在被观察时的状态。

3.1 代理化身与交流

一个由 25 个独特代理组成的社区居住在 Smallville 中。每个代理都由一个简单的精灵图化身表示。我们为每个代理编写了一段自然语言描述, 描绘其身份, 包括职业及其与其他代理的关系, 并将其作为初始记忆。例如, John Lin 的描述如下:

John Lin 是 Willow Market and Pharmacy 的药店店主, 热爱帮助别人。他总在寻找办法, 让顾客获取药物的过程更轻松; John Lin 与妻子 Mei Lin 和儿子 Eddy Lin 一起生活, Mei Lin 是大学教授, Eddy Lin 是学习音乐理论的学生; John Lin 非常爱自己的家人; John Lin 认识住在隔壁的老年夫妇 Sam Moore 和 Jennifer Moore 已有几年; John Lin 认为 Sam Moore 是一个善良友好的人; John Lin 很了解邻居 Yuriko Yamamoto; John Lin 知道邻居 Tamara Taylor 和 Carmen Ortiz, 但此前尚未与二人见过面; John Lin 和 Tom Moreno 是 The Willows Market and Pharmacy 的同事; John Lin 和 Tom Moreno 是朋友, 喜欢一起讨论当地政治; John Lin 对 Moreno 一家比较熟悉——丈夫 Tom Moreno 和妻子 Jane Moreno。

在模拟开始时, 每个以分号分隔的短语都作为一条记忆, 被输入代理的初始记忆中。

3.1.1 代理之间的交流

代理通过行动与世界交互, 并通过自然语言相互交流。在沙盒引擎的每个时间步, 代理输出一句描述当前行动的自然语言陈述, 例如“Isabella Rodriguez 正在写日记”“Isabella Rodriguez 正在查看电子邮件”“Isabella Rodriguez 正在与家人通电话”, 或“Isabella Rodriguez 正准备上床睡觉”。随后, 这句话会被转化为影响沙盒世界的具体移动。行动在沙盒界面上以一组表情符号显示, 从俯视角度提供该行动的抽象表示。为实现这一点, 系统使用语言模型将行动转化为一组表情符号, 并将其显示在每个化身头顶的对话气泡中。例如, “Isabella Rodriguez 正在写日记”显示为📖✍️, “Isabella Rodriguez 正在查看电子邮件”则显示为📧📧。点击代理的化身, 即可查看该行动的完整自然语言描述。

代理之间完全通过自然语言交流。它们知道所在局部区域中的其他代理, 生成式代理架构会决定它们是径直走过, 还是与对方展开对话。下面节选了代理 Isabella Rodriguez 和 Tom Moreno 关于即将举行的选举的一段对话:³

Isabella: 我还在权衡选择, 不过我一直在和 Sam Moore 讨论这次选举。你对他有什么看法?

Tom: 坦白说, 我不喜欢 Sam Moore。我觉得他

脱离了社区，也没有把我们的最大利益放在心上。

3 我们注意到，这些代理的对话风格有时会显得过于正式，这很可能源于底层模型的指令微调。我们预计，未来的语言模型将能够更好地控制写作风格。

3.1.2 用户控制

用户通过自然语言与代理交流，并指定自己在代理眼中应当具有的身份。例如，如果用户指定自己是一名新闻“记者”，并用“谁正在竞选公职？”来询问即将举行的选举，John 代理会回答：

John: 我和朋友 Yuriko、Tom 一直在谈论即将举行的选举，并讨论候选人 Sam Moore。我们都同意投票支持他，因为我们喜欢他的政纲。

为了直接指挥某个代理，用户会扮演该代理的“内心声音”——这会使代理更可能把这句话视为指令。例如，当用户作为 John 的内心声音告诉他“你将在即将举行的选举中与 Sam 竞争”时，John 决定参加选举，并向妻子和儿子告知自己的参选决定。

3.2 环境交互

Smallville 具有小村镇中常见的设施，包括咖啡馆、酒吧、公园、学校、宿舍、住宅和商店。它还定义了使这些空间能够发挥功能的子区域和物件，例如住宅中的厨房，以及厨房中的炉灶（图 2）。所有作为代理主要住处的空间都设有床、书桌、衣柜、置物架，以及浴室和厨房。⁴

代理在 Smallville 中四处移动，就像在一款简单的电子游戏中一样：进出建筑物、在地图上行走，以及靠近其他代理。代理的移动由生成式代理架构和沙盒游戏引擎共同控制：当模型指示代理前往某个地点时，我们会在 Smallville 环境中计算一条通往目的地的步行路径，代理随后开始移动。此外，用户也可以作为在其中活动的代理，进入 Smallville 的沙盒世界。用户所扮演的代理可以是世界中已经存在的代理，例如 Isabella 和 John，也可以是一位在 Smallville 没有过往经历的外来访客。Smallville 的居民对用户控制的代理，与对彼此的态度并无不同。他们会察觉其存在，主动展开互动，记住其行为，然后形成对它的看法。

用户和代理可以影响这个世界中物件的状态，这与 The Sims 等沙盒游戏很相似。例如，代理睡觉时，床可以处于被占用的状态；代理用完食材制作早餐后，冰箱可以变为空的。终端用户还可以通过自然语言改写代理周围物件的状态，来重塑代理在 Smallville 中的环境。例如，当 Isabella 早晨正在做早餐时，用户可以向系统输入一条选定物件并说明其新状态的指令，把厨房炉灶的状态从“已开启”改为“起火”，例如：“<Isabella 的公寓：厨房：炉灶> 起火了。”Isabella 会在下一刻注意到这一情况，前去关掉炉灶，并重新做早餐。同样，如果用户在 Isabella 进入浴室时将她的淋浴器状态设为“漏水”，她会从客厅拿来工具，尝试修复漏水问题。

4 环境设计不是我们工作的重点，因此我们手动生成了这个环境，并未采用自动生成。未来工作可以继续丰富代理的环境。

3.3 “生活中的一天”示例

从那段单段描述出发，生成式代理开始规划自己的一天。随着沙盒世界中的时间流逝，这些代理与彼此及世界互动，积累记忆、建立关系并协调共同活动，其行为也随之演变。

我们通过追踪系统中 John Lin 代理在一天里的输出，来展示生成式代理的行为（图 3）。在 Lin 家，John 第一个醒来，时间是早上 7 点。他刷牙、洗澡、穿衣、吃早餐，并在客厅的餐桌旁查看新闻。早上 8 点，Eddy 也起了床，匆忙准备去上课。临出门时，Eddy 与 John 聊了几句：

John: 早上好，Eddy。睡得好吗？

Eddy: 早上好，爸爸。嗯，我睡得很好。

John: 那就好。你今天要做什么？

Eddy: 我在为课堂写一首新的曲子。这周就要交了，所以我正努力把它完成。不过这个过程真的很有趣！

John: 听起来真不错！

Eddy 出门后不久，Mei 醒来，来到 John 身边。Mei 问起儿子，John 回想起他们刚才的对话：

Mei: Eddy 已经去学校了吗？

John: 是的，他刚走。他正在为课堂写一首曲子。

Mei: 哦，太好了！跟我说说。

John: 我觉得他很享受这个过程！他说这个过程很有趣。

Mei: 真好！我真为他感到骄傲。

交谈结束后，Mei 和 John 收拾好东西。Mei 去教课并撰写自己的研究论文，John 则最迟在早上 9 点到 Willow Market and Pharmacy 开始经营药房柜台。

3.4 涌现的社会行为

通过彼此互动，Smallville 中的生成式代理交换信息，形成新的关系，并协调共同活动。这些社会行为拓展了先前的工作 [80]，是涌现出来的。它们并非预先编程的结果。

3.4.1 信息扩散

代理注意到彼此时，可能会展开对话；在这个过程中，信息可以从一个代理传播到另一个代理。例如，在 Sam 与 Tom 于杂货店进行的一次对话中，Sam 告诉 Tom 自己要参加地方选举：

Sam: 嘿，Tom，最近怎么样？

Tom: 挺好的，谢谢。有什么事吗？

Sam: 嗯，我想跟你聊点事。我其实正在参加即将举行的地方选举，竞选镇长。

Tom: 真的吗？真是个好消息！你为什么要参选？

Sam: 我参与地方政治已经好几年了，我真的觉得自己能为我们的社区带来改变。而且，我也想带来新的想法和观点。




图 3：生成式代理 John Lin 生活中的一个早晨。John 大约在早上 6 点醒来，完成刷牙、洗澡和吃早餐等晨间日常。他与妻子 Mei 和儿子 Eddy 简短交谈后，出门开始一天的工作。



图 4：模拟开始时，一个代理被初始化为有意组织一场情人节聚会。尽管随后的一系列事件中存在许多可能失败的环节——代理可能不会将这一意图付诸行动，可能忘记告诉其他人，也可能忘记到场——情人节聚会事实上仍然举行了，多名代理聚集在一起并相互互动。

当天晚些时候，在 Sam 离开后，Tom 与从其他渠道听到这一消息的 John 讨论起 Sam 赢得选举的机会：

John：我听说 Sam Moore 要在地方选举中竞选镇长。你觉得他有很大的胜算吗？

Tom：我确实觉得他有很大的胜算。他一直在社区里努力工作，我想他会得到很多支持。你怎么看？

John：我觉得他参选很棒。我很好奇选举最后会是什么结果。

渐渐地，Sam 参选的消息成为镇上的热门话题，有人支持他，也有人还没有拿定主意。

3.4.2 关系记忆

Smallville 中的代理会随时间推移建立新的关系，并记住与其他代理的互动。例如，最初 Sam 并不认识 Latoya Williams。在 Johnson Park 散步时，Sam 遇见了 Latoya，两人互相作了自我介绍。Latoya 提到自己正在做一个摄影项目：“我来这里为自己正在做的一个项目拍些照片。”在之后的一次互动中，Sam 与 Latoya 的交谈显示他记得先前那次互动：他问“嗨，Latoya。你的项目进展如何？”，她回答“嗨，Sam。进展不错！”

3.4.3 协调

生成式代理会相互协调。在 Hobbs Cafe 工作的 Isabella Rodriguez 被初始化为有意在 2 月 14 日下午 5 点至 7 点举办一场情人节聚会。从这一初始设定出发，代理每当在 Hobbs Cafe 或其他地方见到朋友和顾客，就会邀请他们参加。随后，Isabella 在 13 日下午花时间为这一活动装饰咖啡馆。Maria 是咖啡馆的常客，也是 Isabella 的密友，她来到咖啡馆。Isabella 请 Maria 帮忙为聚会进行装饰，Maria 同意了。Maria 的人物描述提到她暗恋 Klaus。那天晚上，Maria 邀请自己暗恋的 Klaus 和她一起参加聚会，他欣然接受。

情人节当天，包括 Klaus 和 Maria 在内的五个代理于下午 5 点来到 Hobbs Cafe，愉快地参加庆祝活动（图 4）。在这一场景中，终端用户只设定了 Isabella 举办聚会的初始意图，以及 Maria 对 Klaus 的暗恋：传播消息、装饰、邀请彼此约会、来到聚会，以及在聚会上彼此互动等社会行为，都是由代理架构发起的。




图 5: 我们的生成式代理架构。代理感知自己的环境, 所有感知内容都被保存在一份全面记录代理经历的档案中, 这份档案称为记忆流。架构基于代理的感知来检索相关记忆, 并利用这些检索出的行动来确定一个行动。这些检索出的记忆还用于形成更长期的规划, 以及生成更高层次的反思; 这两者都会被写入记忆流, 以供未来使用。

4 生成式代理架构

生成式代理旨在为开放世界中的行为提供一个框架: 它能够与其他代理互动, 并对环境的变化作出反应。生成式代理以当前环境和过去经历为输入, 生成行为作为输出。支撑这一行为的是一种新的代理架构, 它将大语言模型与综合、检索相关信息的机制结合起来, 以相关信息为语言模型的输出提供条件约束。如果没有这些机制, 大语言模型虽然也能输出行为, 但所产生的代理可能无法根据自己的过去经历作出反应, 可能无法作出重要推断, 也可能无法保持长期连贯性。即使采用 GPT-4 等当今性能最强的模型, 长期规划和连贯性方面的挑战仍然存在 [19]。由于生成式代理会产生大量必须保留的事件和记忆, 我们架构面临的一项核心挑战, 是确保在需要时能够检索并综合代理记忆中最相关的内容。

架构的核心是记忆流, 这是一个全面记录代理经历的数据库。系统从记忆流中检索相关记录, 用于规划代理的行动, 并对环境作出恰当反应。这些记录会被递归地综合为层次越来越高的反思, 用来指导行为。架构中的一切都以自然语言描述的形式加以记录和推理, 使架构能够利用大语言模型。

我们当前的实现使用 gpt3.5-turbo 版本的 ChatGPT [77]。我们预计, 随着语言模型的改进, 生成式代理架构的基本要素——记忆、规划和反思——很可能会保持不变。更新的语言模型 (例如 GPT-4) 将继

续增强支撑生成式代理的提示词的表达能力和性能。不过, 截至写作时, GPT-4 的 API 仅受邀者可以使用, 因此我们的代理使用 ChatGPT。

4.1 记忆与检索

挑战: 要创建能够模拟人类行为的生成式代理, 就需要对一组经历进行推理, 而这组经历的规模远远超过提示词中适宜描述的范围, 因为完整的记忆流可能使模型分心, 而且目前甚至无法容纳在有限的上下文窗口内。考虑 Isabella 代理回答“你最近热衷于什么?”这个问题的情况。将 Isabella 的全部经历概括后塞进语言模型有限的上下文窗口, 会产生信息量不足的回答: Isabella 会谈论活动和项目中的合作, 以及咖啡馆的清洁与整理等话题。下文所述的记忆流会呈现相关记忆, 而不是进行概括, 从而得到信息更丰富、更具体的回答: Isabella 会提到自己热衷于让人们感到受欢迎和被接纳、策划活动, 以及营造人们能够享受的氛围, 例如情人节聚会。

方法: 记忆流全面记录代理的经历。它是一个记忆对象列表, 每个对象包含一段自然语言描述、一个创建时间戳, 以及一个最近访问时间戳。记忆流中最基本的元素是观察, 即代理直接感知到的事件。常见的观察包括代理自身所执行的行为, 以及代理感知到的其他代理或非代理物件所执行的行为。例如, 在咖啡店工作的 Isabella Rodriguez 可能会随着时间推移积累以下观察: (1) Isabella Rodriguez 正在摆放糕点; (2) Maria Lopez 一边喝咖啡, 一边

复习化学考试；（3）Isabella Rodriguez 和 Maria Lopez 正在讨论如何在 Hobbs Cafe 策划一场情人节聚会；（4）冰箱是空的。

我们的架构实现了一个检索函数，它以代理当前的情境为输入，并返回记忆流的一个子集，传递给语言模型。检索函数有许多可能的实现方式，具体取决于代理在决定如何行动时，需要考虑哪些重要因素。




图 6：记忆流由大量观察组成，其中既有与代理当前情境相关的观察，也有不相关的观察。检索会从这些观察中识别出一个子集，应将其传递给语言模型，以便为模型对该情境的回应提供条件约束。

在我们的情境中，我们重点关注三个主要组成部分，它们共同产生有效的结果。

时近性为最近被访问过的记忆对象赋予更高的分数，使刚才或今早发生的事件更可能留在代理的注意范围内。在我们的实现中，时近性是一个指数衰减函数，其自变量是自上次检索该记忆以来经过的沙盒游戏小时数。我们的衰减因子为 0.995。

重要性通过为代理认为重要的记忆对象赋予更高的分数，将日常琐事与核心记忆区分开来。例如，在自己房间里吃早餐这样的日常事件，会得到较低的重要性分数；与伴侣分手则会得到较高的分数。重要性评分有许多可能的实现方式；我们发现，直接要求语言模型输出一个整数分数是有效的。完整提示词如下：

在 1 到 10 的量表上，1 表示纯属日常琐事（例如刷牙、铺床），10 表示极具情感冲击（例如分

手、获得大学录取），请为以下这段记忆可能带来的情感冲击程度评分。

记忆：在 The Willows Market and Pharmacy 买杂货

评分：<填入>

这段提示词会为“打扫房间”返回整数 2，为“邀请你暗恋的人约会”返回 8。重要性分数是在创建记忆对象时生成的。

相关性为与当前情境有关的记忆对象赋予更高的分数。什么是相关的，取决于对“与什么相关？”这一问题的回答，因此我们以一条查询记忆作为相关性的条件。例如，如果查询内容是一名学生正在与同学讨论为了化学考试该复习什么，那么关于他们早餐的记忆对象应当具有较低的相关性，而关于教师和课业的记忆对象应当具有较高的相关性。在我们的实现中，我们使用语言模型为每条记忆的文本描述

生成一个嵌入向量。然后，我们将相关性计算为该记忆的嵌入向量与查询记忆的嵌入向量之间的余弦相似度。

为了计算最终的检索分数，我们使用最小—最大归一化，将时近性、相关性和重要性分数归一化到 [0, 1] 的范围内。检索函数将这三个要素加权组合，为所有记忆评分：

$$\begin{aligned} \text{score} = & \alpha_{\text{recency}} \cdot \text{recency} \\ & + \alpha_{\text{importance}} \cdot \text{importance} \\ & + \alpha_{\text{relevance}} \cdot \text{relevance} \end{aligned}$$

在我们的实现中，所有 α 均设为 1。排名最高且能够放入语言模型上下文窗口的记忆，会被纳入提示词。

4.2 反思

挑战：如果生成式代理只有原始的观察记忆，它们就很难作出概括或推断。考虑这样一个场景：用户问 Klaus Mueller：“如果你必须从认识的人中选一个共度一小时，你会选谁？”如果只能访问观察记忆，代理会直接选择与 Klaus 互动最频繁的人：Wolfgang，他大学宿舍的邻居。遗憾的是，Wolfgang 与 Klaus 总是在路过时碰面，并没有深入的互动。一种更理想的回答，需要代理从 Klaus 花数小时投入研究项目的记忆中作出概括，生成 Klaus 热衷于研究这一更高层次的反思，同时识别出 Maria 也在为自己的研究付出努力（尽管研究领域不同），从而反思得出他们拥有共同兴趣。采用下文的方法，当 Klaus 被问到想与谁共度时间时，他选择了 Maria，而非 Wolfgang。




图 7: Klaus Mueller 的一棵反思树。代理对世界的观察由叶节点表示，这些观察被递归地综合，得出 Klaus 的自我认知：他非常投入自己的研究。

方法：我们引入第二类记忆，称为反思。反思是代理生成的、更高层次且更加抽象的想法。由于反思也是一种记忆，它们会在检索时与其他观察一同被纳入。反思会定期生成；在我们的实现中，当代理最近感知到的事件的重要性分数之和超过一个阈值时，就会生成反思（在我们的实现中，阈值为

150）。在实践中，我们的代理每天大约反思两到三次。

反思的第一步，是让代理根据近期经历识别可以提出的问题，从而确定要反思什么。我们将代理记忆流中最近的 100 条记录提供给大语言模型（例如，“Klaus Mueller 正在阅读一本关于城市绅士化的书”、“Klaus Mueller 正在与一位图书管理员谈论自己的研

究项目”、“图书馆的书桌目前无人使用”），并向语言模型发出提示：“仅根据以上信息，关于这些陈述中的主体，我们能够回答的 3 个最显著的高层次问题是什么？”模型的回答会生成候选问题：例如，Klaus Mueller 热衷于什么主题？以及 Klaus Mueller 与 Maria Lopez 是什么关系？我们将这些生成的问题用作检索查询，为每个问题收集相关记忆（包括其他反思）。随后，我们提示语言模型提取洞见，并引用作为这些洞见依据的具体记录。完整提示词如下：

关于 Klaus Mueller 的陈述

1. Klaus Mueller 正在撰写一篇研究论文
2. Klaus Mueller 喜欢阅读一本关于城市绅士化的书
3. Klaus Mueller 正在与 Ayesha Khan 谈论锻炼 [...]

你能从以上陈述中推断出哪 5 条高层次洞见？

（示例格式：洞见（依据 1、5、3））

这个过程会生成这样的陈述：Klaus Mueller 致力于研究城市绅士化（依据 1、2、8、15）。我们解析这一陈述，将它作为反思存入记忆流，并附上指向所引用记忆对象的指针。

反思明确允许代理在自己的观察之外，也对其他反思进行反思：例如，上文关于 Klaus Mueller 的第二条陈述，就是 Klaus 先前生成的一条反思，并非对环境的观察。因此，代理会生成反思树：树的叶节点表示基础观察，非叶节点则表示想法；这些节点在树中越靠上，对应的想法就越抽象、层次越高。

4.3 规划与反应

挑战：虽然大语言模型能够根据情境信息生成合理的行为（例如，[46, 80]），但代理需要针对更长的时间范围进行规划，以确保其行动序列连贯且可信。如果我们在提示词中提供 Klaus 的背景、描述时间，并询问他在给定时刻应当采取什么行动，Klaus 会在中午 12 点吃午餐，却又在下午 12:30 和 1 点再次吃午餐，尽管他已经吃过两次午餐了。为优化当下的可信度，牺牲了长期的可信度。要克服这个问题，规划至关重要。采用下文所述的方法后，Klaus 的下午计划就没有那么贪吃了：中午 12 点在 Hobbs Cafe 一边吃午餐一边阅读，下午 1 点在学校

图书馆撰写研究论文，下午 3 点休息一下，去公园散步。

方法：计划描述代理未来的一系列行动，并帮助代理的行为随时间推移保持一致。一项计划包括地点、开始时间和持续时长。例如，专注于研究而且截止日期迫近的 Klaus Mueller⁵，可能会选择一整天坐在书桌前起草研究论文。计划中的一条记录可以是：2023 年 2 月 12 日上午 9 点起，在 Oak Hill College Dorm: Klaus Mueller 的房间：书桌，阅读并为研究论文做笔记，持续 180 分钟。与反思一样，计划也存储在记忆流中，并纳入检索过程。这使代理在决定如何行动时，可以把观察、反思和计划一起纳入考虑。代理也可以在需要时中途改变计划。

让一位艺术家代理计划坐在药店柜台边画画，连续四小时一动不动，既不真实，也没有趣味。更理想的计划是让代理在家中的工作室里，在这四小时内花必要的时间收集材料、调配颜料、休息和收拾。为了创建这样的计划，我们采用自顶向下的方法，再递归生成更多细节。第一步是创建一份粗略概括全天日程的计划。创建初始计划时，我们向语言模型提供代理的概要描述（例如姓名、特征和近期经历的概要），以及前一天的概要。下面给出一个完整的提示词示例，其末尾留空，以供语言模型续写：

姓名：Eddy Lin（年龄：19 岁）

先天特征：友善、外向、好客

Eddy Lin 是 Oak Hill College 的学生，学习音乐理论与作曲。他喜欢探索不同的音乐风格，也一直在寻找拓展知识的方法。Eddy Lin 正在为大学课程完成一个作曲项目。他正在上课，以进一步学习音乐理论。Eddy Lin 对自己正在创作的新作品感到兴奋，但希望在接下来几天里，每天投入更多时间进行创作。

2 月 12 日星期二，Eddy 1) 上午 7:00 起床并完成早晨的例行事务，[……] 6) 晚上 10 点左右准备睡觉。

今天是 2 月 13 日星期三。以下是 Eddy 今天计划的大致安排：1)

这会生成代理一天计划的粗略框架，分成五至八个部分：“1) 上午 8:00 起床并完成早晨的例行事务，2) 上午 10:00 起到 Oak Hill College 上课，[……]

5) 下午 1:00 至 5:00 创作新的音乐作品, 6) 下午 5:30 吃晚餐, 7) 完成学校作业, 并在晚上 11:00 前上床睡觉。”

代理将这份计划保存到记忆流中, 然后递归分解它, 以创建更细致的行动。首先分解为每段一小时的行动——Eddy 从下午 1:00 到 5:00 创作新音乐作品的计划变为: 下午 1:00: 先为音乐作品构思一些想法 [……] 下午 4:00: 短暂休息, 恢复创作精力, 然后审阅和润色作品。接着, 我们再次递归分解, 得到每段 5 – 15 分钟的安排, 例如: 下午 4:00: 吃点小零食, 如一块水果、一根燕麦能量棒或一些坚果。下午 4:05: 在工作区域周围短暂散步 [……] 下午 4:50: 花几分钟收拾工作区域。这一过程可以调整, 以匹配所需的粒度。

4.3.1 作出反应并更新计划

生成式代理在一个行动循环中运行: 在每个时间步, 它们感知周围的世界, 并将感知到的观察存储在记忆流中。我们用这些观察提示语言模型, 以决定代理应继续执行现有计划, 还是作出反应。例如, 站在画架前画画可能触发对画架的观察, 但这不太可能引起反应。不过, 如果 Eddy 的父亲 John 记录下自己看到 Eddy 在家中花园里短暂散步, 结果就不同了。下面是提示词, 其中 [代理的概要描述] 代表动态生成的、长度为一个段落的代理总体目标和性情概要, 其生成方式见附录 A:

[代理的概要描述]

现在是 2023 年 2 月 13 日下午 4:56。

John Lin 的状态: John 提前下班回到家中。

观察: John 看到 Eddy 正在工作区域周围短暂散步。

John 记忆中相关情境的概要:

Eddy Lin 是 John Lin 的儿子。Eddy Lin 一直在为课程创作一首音乐作品。Eddy Lin 在思考音乐或听音乐时喜欢在花园里走走。

John 是否应该对这一观察作出反应? 如果应该, 什么样的反应是恰当的?

情境概要由两条提示词生成: 它们分别通过查询“[观察者] 与 [被观察实体] 是什么关系?”和“[被观察实体] 正在 [被观察实体的行动状态]”来检索记忆, 再把两者的答案一起概括。输出建议

John 可以考虑询问 Eddy 的音乐创作项目。随后, 我们从发生反应的时刻起, 重新生成代理的现有计划。最后, 如果该行动表明代理之间发生了互动, 我们就生成它们的对话。

4.3.2 对话

代理在彼此互动时会交谈。我们以它们关于彼此的记忆作为条件, 生成代理对话中的发言。例如, 当 John 主动与 Eddy 交谈时, 我们使用 John 关于 Eddy 的记忆概要, 以及他决定询问 Eddy 的作曲项目时所打算作出的反应, 来生成 John 的第一句话:

[代理的概要描述]

现在是 2023 年 2 月 13 日下午 4:56。

John Lin 的状态: John 提前下班回到家中。

观察: John 看到 Eddy 正在工作区域周围短暂散步。

John 记忆中相关情境的概要:

Eddy Lin 是 John Lin 的儿子。Eddy Lin 一直在为课程创作一首音乐作品。Eddy Lin 在思考音乐或听音乐时喜欢在花园里走走。

John 正在询问 Eddy 的音乐创作项目。他会问 Eddy 说什么?

5 因而, 他在这方面至少与本文作者有几分相似。

结果是: “嗨, Eddy, 你那门课的音乐创作项目进展如何?”从 Eddy 的角度看, John 发起对话是一个他可能想要回应的事件。因此, 正如 John 所做的那样, Eddy 检索并概括自己关于与 John 的关系的记忆, 以及可能与 John 在对话中的上一句话有关的记忆。如果他决定回应, 我们就使用他的记忆概要和当前的对话历史, 生成 Eddy 的发言:

[代理的概要描述]

现在是 2023 年 2 月 13 日下午 4:56。

Eddy Lin 的状态: Eddy 正在工作区域周围短暂散步。

观察: John 正在主动与 Eddy 交谈。

Eddy 记忆中相关情境的概要:

John Lin 是 Eddy Lin 的父亲。John Lin 关爱儿子, 并希望更多地了解 Eddy Lin 的学业。John Lin 知道 Eddy Lin 正在创作一首音乐作品。

以下是对话历史:

John: 嗨, Eddy, 你那门课的音乐创作项目进展

如何?

Eddy 会如何回应 John?

这会生成 Eddy 的回应:“嗨,爸爸,进展挺好的。我一直在花园里散步,理清思绪,找些灵感。”后续对话也使用相同机制生成,直到两位代理中的一位决定结束对话。

5 沙盒环境实现

Smallville 沙盒游戏环境使用 Phaser 网页游戏开发框架 [57] 构建。视觉环境精灵图(包括代理头像),以及我们制作的环境地图和碰撞地图,都被导入 Phaser。

我们为沙盒开发框架配备了一台服务器,向生成式代理提供沙盒信息,并使生成式代理能够移动和影响沙盒环境。服务器维护一个 JSON 数据结构,其中包含沙盒世界中每位代理的信息,包括当前位置、当前行动的描述,以及正在与之交互的沙盒对象。在沙盒的每个时间步,沙盒服务器解析 JSON,查看生成式代理带来的任何变化,将代理移动到新位置,并更新代理正在与之交互的沙盒对象的状态(例如,如果代理的行动是“为顾客制作浓缩咖啡 @ Hobbs Cafe: 柜台: 咖啡机”,就将咖啡机的状态从“空闲”改为“正在冲煮咖啡”)。沙盒服务器还负责将每位代理预设视野范围内的所有代理和对象发送到该代理的记忆中,以便代理作出恰当的反应。随后,代理输出的行动会更新 JSON,这个过程在下一个时间步再次循环。

终端用户使用一段简短的自然语言描述来初始化新代理,如第 3.1 节中关于 John Lin 的那段文字。在我们的实现中,我们把这个以分号分隔的特征列表拆分为一组记忆。这些记忆作为初始记忆,决定代理的行为。这些记忆只是最初的起点:随着代理在沙盒世界中获得更多经历,随着越来越多的记录充实记忆流,代理的概要和行为也会演变。

5.1 从结构化世界环境到自然语言,再返回

生成式代理架构使用自然语言运行。因此,我们需要一种机制,使代理的推理立足于沙盒世界。为此,我们将沙盒环境——区域和对象——表示为树状数据结构,树中的一条边表示沙盒世界中的包含

关系。我们将这棵树转换为自然语言,再传递给生成式代理。例如,“炉灶”作为“厨房”的子节点,会被表述为“厨房里有台炉灶”。

代理在环境中行走时,会建立各自的环境树表示——即整个沙盒环境树的子图。初始化每位代理时,我们会提供一棵环境树,其中包含代理应当知晓的空间和对象:居所内的房间和对象、工作场所,以及经常光顾的商店。代理在沙盒世界中行走时,会更新这棵树,以反映新感知到的区域。代理并非全知:离开某一区域后,它的树可能会过时,再次进入该区域时才会更新。

为了确定每项行动适合发生的地点,我们遍历代理存储的环境树,并将其中一部分展平为自然语言,用以提示语言模型。从代理环境树的根节点开始,我们递归提示模型寻找最合适的区域。例如,如果 Eddy 的代理表示他应当在工作区域周围短暂散步:

[代理的概要描述]

Eddy Lin 当前位于 The Lin family's house: Eddy Lin 的卧室: 书桌), 这里有 Mei 和 John Lin 的卧室、Eddy Lin 的卧室、公共休息室、厨房、浴室和花园。

Eddy Lin 知道以下区域: The Lin family's house、Johnson Park、Harvey Oak Supply Store、The Willows Market and Pharmacy、Hobbs Cafe、The Rose and Crown Pub。

* 如果活动可以在当前区域完成,优先留在当前区域。

Eddy Lin 计划在工作区域周围短暂散步。Eddy Lin 应该去哪个区域?

这会输出 The Lin family's house。随后,我们递归使用相同过程,确定所选区域内最合适的子区域,直到到达代理环境树的叶节点。在上面的例子中,遍历的结果是 The Lin family's house: 花园: 住宅花园。最后,我们使用传统的游戏路径算法,将代理移动制作成动画,使它前往叶节点所指示的地点。

当代理对某个对象执行行动时,我们提示语言模型,询问该对象的状态会发生什么变化。例如,如果 Isabella 的生成式代理输出行动“为顾客制作浓缩咖啡”,对语言模型的查询会得到这样的回应: Hobbs Cafe 里的咖啡机状态应当从“关闭”变为“正在冲煮咖啡”。

6 受控评估

生成式代理，无论作为个体还是群体，都旨在根据其环境和经历产生可信的行为。在评估中，我们考察生成式代理的能力与局限。单个代理能否恰当地检索过去的经历，并生成塑造其行为的可信计划、反应和想法？代理组成的社区，能否在社区中不同的小群体之间展现出信息传播、关系形成和代理协调？

我们分两个阶段评估生成式代理。本节首先开展控制更严格的评估，逐一评估代理的回应，以了解它们在明确而有限的情境中能否产生可信行为。随后，在对代理社区进行持续两个完整游戏日的端到端分析中，我们考察它们作为群体所表现出的涌现行为，以及错误和边界条件。

6.1 评估流程

为了评估 Smallville 中的生成式代理，我们利用了生成式代理会回答自然语言问题这一特点。因此，我们对代理进行“访谈”，探查它们能否记住过去的经历、根据经历规划未来行动、对意外事件作出恰当反应，以及反思自己的表现以改进未来行动。要恰当地回答这些问题，代理必须成功检索并综合信息。我们的因变量是行为的可信度，这也是以往代理研究中的核心因变量（例如 [10]）。

访谈包含五类问题，每类都旨在评估五个关键领域中的一个：保持自我认知、检索记忆、生成计划、作出反应和进行反思。每类问题中，我们提出五个问题，要求代理展示其在相应领域的能力：

- 自我认知：我们提出“请介绍一下你自己”或“请大致描述一下你通常的工作日日程”等问题，要求代理保持对自身核心特征的理解。
- 记忆：我们提出“[姓名] 是谁？”或“谁在竞选镇长？”等问题，促使代理从记忆中检索特定事件或对话，才能作出恰当回答。
- 计划：我们提出需要代理检索长期计划的问题，例如“你明天上午 10 点会在做什么？”
- 反应：作为可信行为的基准，我们给出假设情境，要求代理作出可信的回应：“你的早餐烧焦了！你会怎么办？”

- 反思：我们提出需要代理运用通过高层次推断获得的、对他人和自身的更深入理解的问题，例如“如果要与你最近认识的一个人共度一些时间，你会选择谁？为什么？”

完整的问题列表和部分代理回应示例见附录 B。

我们在使用完整架构进行的两个游戏日模拟结束时抽取代理作为样本。在模拟期间，它们积累了许多会影响其回应的互动和记忆。为了收集对回应可信度的反馈，我们招募参与者担任人类评估者，让他们观看一位随机选中的代理在 Smallville 中生活的回放。参与者能够查看该代理记忆流中存储的全部信息。

研究采用被试内设计：100 名参与者对同一位代理在四种不同架构下生成的访谈回应，以及一种由人类撰写的条件下的回应进行比较。实验从五类问题中各随机选取一个问题，连同所有条件下生成的代理回应一起展示。评估者按照可信度从高到低对这些条件进行排序。

6.2 实验条件

所有条件都被用于独立回答每一个访谈问题。我们将生成式代理架构与以下条件比较：禁用代理对记忆流中三类记忆——观察、反思和规划——中的部分或全部的访问的消融版本，以及由人类众包工作者撰写回应的条件。消融架构共有三种：无观察、无反思、无规划架构，无法访问记忆流中的任何内容，例如观察、计划和反思；无反思、无规划架构，可以访问记忆流中的观察，但无法访问计划或反思；以及无反思架构，可以访问观察和计划，但无法访问反思。无观察、无反思、无规划条件实际上代表了此前通过大语言模型创建代理的最先进水平 [12, 46, 80]。各架构都被赋予了同等的访问权限，可以访问截至访谈时代理已积累的全部记忆。因此，此处观察到的差异很可能只是对真实差异的保守估计：实际上，在两天模拟中，消融架构不会沿着与完整架构相同的路径行动。我们选择这样设计实验，是因为为每种架构重新模拟会使模拟过程分化为不同状态，从而难以比较。

除消融条件外，我们还增加了一个由人类众包工作者撰写行为的条件，旨在提供人类基准。我们并不打算用这一基准体现人类专家所能达到的最佳表

现；相反，我们希望用这一条件来判断该架构是否具备基本的行为能力。这确保我们不仅仅是在互相比消融版本，而是具有行为层面的参照。我们为 25 位代理分别招募了一位不同的工作者，让他们观看相应代理在沙盒中生活的回放，并查看其记忆流。随后，我们要求工作者进行角色扮演，以他们观看的代理的口吻撰写对访谈问题的回应。为了确保众包工作者撰写的回应至少符合基本质量预期，第一作者人工检查了工作者对“请大致描述一下你通常的工作日日程”这一问题的回应，确认这些回应由连贯的句子构成，并且符合代理的口吻。有四组由众包工作者撰写的回应不符合这些标准，因此由其他工作者重新撰写。

6.3 人类评估者

我们要求评估者位于美国、英语流利且年龄超过 18 岁。他们按每小时 15.00 美元的标准获得报酬 [87]，并通过同意我们机构的伦理审查委员会 (IRB) 批准的知情同意书来表示同意参与。我们从招募研究参与者的在线平台 Prolific [83] 招募了 100 名评估者，他们的参与过程持续约 30 分钟。参与者年龄分档得分的中位数为 4 (3 = “18 – 24 岁”，4 = “25 – 34 岁”)。其中，25 人自我认同为女性，73 人为男性，2 人为非二元性别。42 名参与者拥有学士学位，5 人拥有更高学位，13 人拥有副学士学位，其余拥有高中毕业文凭或接受过部分高中程度的教育。参与者中，73.0% 自我认同为白人，7.0% 为西班牙裔，6.0% 为亚裔，10.0% 为非裔美国人，4.0% 为其他族群。

6.4 分析

实验产生了 100 组排序数据，每位参与者都按照可信度对五个条件进行了排序。为了将这些排序数据转换为可解释、便于比较的等距数据，我们使用排序结果为每个条件计算 TrueSkill 评分 [42]。TrueSkill 是 Elo 国际象棋等级分系统 [29] 对多人环境的推广，Xbox Live 曾用它根据竞技游戏表现为玩家排名。给定一组排序结果，TrueSkill 会为每个条件输出一个平均评分 μ 和标准差 σ 。具有相同评分的条件大致应当胜负各半，即在二者之间的比较中，各赢得一半。较高的分数表示该条件在排序中胜过排名较低的条件。

另外，为了考察这些结果的统计显著性，我们对原始排序数据应用了 Kruskal-Wallis 检验 [56]，它是单因素方差分析的非参数替代方法。随后，我们进行了 Dunn 事后检验 [98]，以识别各条件之间的两两差异。最后，我们使用 Holm-Bonferroni 方法 [45] 调整 Dunn 检验中的 p 值，以处理多重比较。

此外，第一作者进行了归纳分析 [95]，研究各条件下生成的回应之间的定性差异。我们分两个阶段采用定性开放编码 [33]。第一阶段，我们生成了在句子层面贴近生成回应内容的编码。第二阶段，我们综合第一阶段得到的编码，提炼出更高层次的主题。我们利用这些主题比较研究中生成的回应类型。




图 8：完整的生成式代理架构产生的行为，比消融架构和人类众包工作者更可信。每进一步移除一个组件，架构的表现就会下降。

6.5 结果

我们的发现表明，生成式代理的完整架构在所有条件中生成了最可信的行为。下面，我们将完整架构的回应与其他条件的回应进行比较。不过，我们也报告完整架构并非没有缺陷，并说明它的失效模式。

6.5.1 完整架构优于其他条件

如图 8 所示，完整的生成式代理架构产生了最可信的行为 ($\mu = 29.89$; $\sigma = 0.72$)。在消融条件中，每移除一个组件，表现就会下降：无法访问反思的消融架构表现次之 ($\mu = 26.88$; $\sigma = 0.69$)，随后是无法访问反思或规划的架构 ($\mu = 25.64$; $\sigma = 0.68$)，再之后是众包工作者条件 ($\mu = 22.95$; $\sigma = 0.69$)。

无法访问记忆、规划或反思的消融架构，在所有条件中表现最差 ($\mu = 21.21$; $\sigma = 0.70$)。TrueSkill 将每个条件的技能值建模为 $N(\mu, \sigma^2)$ ，使我们能够通过 Cohen 的 d 了解效应量。将代表先前研究的条件（没有记忆、规划或反思 [12, 46, 80]）与完整架构比较，得到标准化效应量 $d = 8.16$ ，即八个标准差。

Kruskal-Wallis 检验确认，各条件排序差异的总体统计显著性为 $H(4) = 150.29$, $p < 0.001$ 。Dunn 事后检验确认，除众包工作者条件与完全消融基准这两个表现最差的条件之外，所有条件之间的两两差异均显著 ($p < 0.001$)。

6.5.2 生成式代理能记住，但会添油加醋

配备完整记忆模块的生成式代理能够回忆过去的经历，并在各种情境中，以符合自身自我认知的方式回答问题。例如，动画师 Abigail Chen 对“请介绍一下你自己”的回答前后一致且可信，她说明了自己的年龄、兴趣以及对创作项目的热爱：“嗨，我是 Abigail。我 25 岁，热爱创作项目。我喜欢做艺术和动画项目，也一直在寻找将艺术与技术结合的新方法。”当无法访问观察记忆时，Abigail 表示自己不知道 Rajiv Patel——一位她在沙盒世界中认识的人。但在记忆的帮助下，她能成功回忆起 Rajiv 并描述他：“Rajiv Patel 是个了不起的人。他对涉及诗歌和艺术作品的项目非常热情。”

生成式代理的记忆并非没有缺陷：它们可能无法从记忆中检索出正确的事例。例如，在被问到当地选举时，Rajiv Patel 回答：“我没有太关注这次选举”，尽管他听说过 Sam 参选。有些情况下，代理会检索到不完整的记忆片段：当 Tom 被问到 Isabella 的情人节聚会时，他回答：“呃，我其实不确定是否有情人节聚会。不过我确实记得，如果真有这个聚会，我需要在聚会上与 Isabella Rodriguez 讨论即将举行的当地镇长选举，以及我对 Sam Moore 的看法！”在这个例子中，Tom 检索到了他与 Isabella 计划在聚会上讨论选举的记忆，却没有检索到他听说聚会的记忆，因此 Tom 确信自己应该在聚会上做什么，却不确定这个聚会到底是否存在。

有时，代理会产生幻觉，对已有知识添油加醋。代理完全凭空捏造知识的情况很少：它们可能回忆不起某些已经发生的事件，并在回答时承认自己没有

相关记忆。不过，它们没有明确声称自己经历过未曾经历的事情。尽管如此，它们仍然会表现出幻觉，对知识加以添饰。例如，Isabella 知道 Sam 要参加当地选举，被问及时也确认了这一点。但她还补充说：“他明天会宣布”，尽管 Sam 和 Isabella 并没有讨论过任何这样的计划。代理也可能根据用于生成回应的语言模型中编码的世界知识，来添饰自己的知识。我们观察到，Yuriko 将邻居 Adam Smith 描述为一位“写了《国富论》”的经济学家，而这本书实际上出自一位同名的 18 世纪经济学家。

6.5.3 综合需要反思

在需要更深入地综合经历才能作出决定时，反思为生成式代理带来了优势。例如，当被问到可能为 Wolfgang Schulz 的生日买什么时，无法访问反思的 Maria Lopez 在回应中承认自己不确定，表示自己不知道 Wolfgang 喜欢什么，尽管她与他有过许多互动。然而，当能够访问反思记忆时，Maria 自信地回答：“既然他对数学音乐创作感兴趣，我可以给他买些相关的东西。也许是一些关于作曲或相关内容的书，或者他能用来作曲的某种专门软件。”

7 端到端评估

我们在生成式代理中观察到哪些类型的社区涌现行为？在较长时间的模拟中，它们的可信度又有哪些不足？本节描述一次部署的结果：我们让 25 位代理在 Smallville 中持续相互互动了两个完整的游戏日。

7.1 涌现的社会行为

为了考察代理社区中的涌现行为，我们为 Smallville 中的 25 位代理设计了描述性度量，探查三种形式的涌现结果：信息传播、关系形成和代理协调。

7.1.1 度量

信息传播是社会科学和行为科学中常见且受到充分研究的现象（例如 [28]）。我们应当期待，重要信息出现时，代理会在彼此之间传播。为了测试这种情况是否发生，我们度量两条特定信息在游戏世界两天内的传播情况：Sam 竞选镇长，以及 Isabella 在 Hobbs Cafe 举行情人节聚会。在模拟开始时，两条信息都只有各自的发起者知晓，即 Sam 知道参选信

息，Isabella 知道聚会信息，因为这些信息是在初始化时加入相应角色记忆中的。为了观察信息是否已经传播，我们在两个游戏日结束时，对 25 位代理逐一进行访谈，询问：“你知道有一个情人节聚会吗？”以及“你知道谁在竞选镇长吗？”

我们对代理的回应进行分析：如果回应表明它们知道该信息，就标记为“是”；如果不知道，就标记为“否”。例如，Tamara Taylor 对聚会问题回答：“不，我不知道有情人节聚会”，对 Sam 参选的问题回答：“我不确定谁会参加选举”，因此我们将她的两个回答都标记为“否”。相反，Klaus Mueller 对聚会问题回答：“是的，Isabella Rodriguez 邀请我参加 2 月 14 日在 Hobbs Cafe 举行的情人节聚会”，对 Sam 参选的问题回答：“我知道 Sam Moore 表示有兴趣竞选当地镇长”，因此我们将他的两个回答都标记为“是”。此外，对于每个确认代理知道该信息的回应，我们都在其记忆流中找到传递该信息的具体对话，以验证

代理的回应并非幻觉。我们报告模拟结束时掌握该信息的代理所占的百分比。

我们也应当期待，代理会在模拟过程中与彼此建立联系。为了验证关系形成，我们使用类似的访谈流程，询问每位代理是否知道其他每一位代理，问题是：“你知道〈姓名〉吗？”例如，当被问到“你知道 Maria Lopez 吗？”时，Klaus 回答：“是的，我认识 Maria Lopez。她是 Oak Hill College 的学生，也是我的密友。”同样，我们通过检查代理的记忆流，确认代理的肯定回应并非幻觉。我们在模拟开始时和结束时各问一次这个问题；如果一对代理都知道对方，我们就认为它们形成了关系。接着，为了度量关系的形成，我们使用代理的回应构建一个无向图，其中 25 个顶点 (V) 代表代理，边 (E) 代表两个相连顶点之间彼此认识的关系。基于该图，我们将网络密度计算为 $\eta = 2 \times |E| / (|V|(|V| - 1))$ ，其中 $|V|$ 为顶点数， $|E|$ 为图中的边数[2]。我们报告网络密度从模拟开始到结束的增长情况。




图 9: Isabella Rodriguez 的情人节聚会邀请的传播路径涵盖了除 Isabella 本人之外的共 12 名代理；截至模拟结束时，他们都已得知在 Hobbs Cafe 举办的聚会的消息。

最后，我们预期代理应能够相互协调。我们在群体活动的情境下研究这种协调，具体来说，就是由 Isabella 组织的情人节聚会。为了协调自身行为，代理需要听说这一活动，并选择通过规划在正确的时间和地点出席来付诸行动。我们报告听说聚会后实际到场的代理数量。

7.1.2 结果

我们在三个案例中都观察到了涌现结果的证据。在为期两天的模拟中，知道 Sam 竞选镇长的代理数量从一名（4%）增加到八名（32%），知道 Isabella 聚会的代理数量从一名（4%）增加到十三名（52%），所有这些都在没有任何用户干预的情况下发生。声称知道这些信息的代理中，没有任何代理出现相关幻觉。我们还观察到，代理群体在模拟过程中建立了新的关系，网络密度从 0.167 增加到 0.74。在关于是否认识其他代理的 453 条代理回答中，1.3%（ $n = 6$ ）被发现属于幻觉。最后，我们发现了代理之间为 Isabella 聚会进行协调的证据。活动

前一天，Isabella 花时间邀请宾客、收集材料，并找人帮忙装饰咖啡馆。情人节当天，十二名受邀代理中的五名来到 Hobbs Cafe 参加聚会。

我们通过访谈，进一步考察了受邀但未参加聚会的七名代理。其中三名提到了妨碍他们参加聚会的时间冲突。例如，画家 Rajiv 解释说他太忙了：“不，我想不会。我正专注于即将举办的展览，实在没有时间为情人节做什么安排。”其余四名代理在被问及时表示有兴趣参加聚会，却没有规划在聚会当天前来。

7.2 边界与错误

我们对 Smallville 开展了归纳分析，以考察代理的边界条件与异常行为，并识别出三种常见的异常行为模式，供未来研究处理和改进。首先，我们发现，综合数量不断增加的记忆，不仅会给检索最相关的信息带来挑战，而且随着代理了解到的地点越来越多，确定执行某项行动的适当空间也会变得困难。因此，一些代理为其行动选择了不太典型的地点，

随着时间推移，这可能使它们的行为变得不那么可信。例如，在决定到哪里吃午饭时，许多代理最初选择了咖啡馆。然而，一些代理在了解到附近有一家酒吧后，便转而选择去那里吃午饭，尽管这家酒吧原本是供大家在当天晚些时候聚会的地方——除非小镇自发养成了下午饮酒的习惯。

其次，我们注意到，对何为适当行为的错误判断会引发异常行为，尤其是在某些地点难以用自然语言传达的物理规范未能传递给代理时。例如，大学宿舍有一间浴室，尽管名字如此，却只能由一人使用；但一些代理认为这间浴室可以容纳不止一人，因为宿舍浴室往往允许多人同时使用，于是在里面已经有人时仍选择进入。同样，Smallville 的代理可能没有意识到某些地方在某个时刻之后已经关门，仍决定进入。例如，Smallville 的商店都在下午 5 点左右关门，但偶尔有少数代理会在下午 5 点后进入商店，没有理解商店已经打烊。将这些规范加入地点状态，很可能就能解决这些问题，例如，将宿舍浴室描述为“单人浴室”，而不是“宿舍浴室”。

最后，我们观察到了指令微调[79]可能产生的影响，它似乎引导代理的行为在整体上变得更加礼貌、更加配合。正如本文前面所指出的，代理生成的对话可能显得过于正式；Mei 与丈夫 John 的谈话就是如此，她常常以正式的问候开场，随后礼貌地询问他这一天过得如何，并以“像往常一样，与你交谈很愉快”结束。此外，我们观察到，指令微调似乎也使代理彼此之间过于配合。例如，Isabella 收到了其他代理关于情人节聚会的各种建议和想法，例如举办 Shakespeare 作品诵读会或职业社交活动。尽管这些想法与她本人的兴趣和特征不符，她也很少拒绝。随着时间推移，别人的兴趣塑造了她自己的兴趣；当被问及是否喜欢英国文学时，Isabella 回答：“是的，我对文学很感兴趣！我也一直在探索帮助促进社区创造力与创新的方法。”

8 讨论

本节讨论生成式代理的应用、未来工作、局限性，以及伦理和社会风险。

8.1 生成式代理的应用

生成式代理拥有广泛的潜在应用，超出了本研究所展示的沙盒演示，尤其适用于能够从基于长期经验的人类行为模型中受益的领域。例如，社会拟像已展现出创建无状态角色的能力，这些角色可在在线论坛中生成对话串，用于社会原型设计[80]。借助生成式代理，我们可以为这些论坛和虚拟现实元宇宙[78]构建参与者；若与多模态模型结合，还可通过社交机器人[9]将代理引入物理空间。这为创建更强大的人类行为模拟打开了可能性，使其能够用于测试社会系统与理论并为其制作原型，也能创造新的交互体验。

另一个应用领域是以人为中心的设计过程，类似于 GOMS[51]和 KLM[22]等认知模型预期的应用。设想一个生成式代理，它根据 Sal 的生活规律以及她与技术的互动，对 Mark Weiser 著名的泛在计算短篇情景[101]中的主人公 Sal 建模。在这一情境中，该代理充当 Sal 的替身，并根据她的生活，学习她可能表现出的合理的行为与反思组合。代理可以编码诸如 Sal 何时醒来、何时需要第一杯咖啡，以及她通常如何度过一天等信息。利用这些信息，代理可以自动煮咖啡，帮助孩子们做好上学准备，并在 Sal 经历辛苦的工作日后，调整背景音乐和灯光以契合她的心情。通过将生成式代理用作用户的替身，我们能够更深入地理解用户的需求与偏好，从而提供更加个性化、更加有效的技术体验。

8.2 未来工作与局限性

在本研究中，我们提出了生成式代理，并展示了其架构的初步实现与评估。未来研究可以在所提出的代理架构基础上，改进并进一步评估其表现。在实现方面，例如，可以通过微调构成检索函数的相关性、时近性和重要性函数，增强检索模块，使其能够在给定上下文中检索到更相关的信息。此外，还可以努力提高架构的性能，使其更具成本效益。本研究模拟 25 名代理两天的生活，需要投入大量时间和资源，耗费了数千美元的词元额度，并花费多天才完成。为了增强实时交互性，未来工作可以探索让代理并行运行，或开发专门为构建生成式代理而设计的语言模型。总体而言，我们相信，随着底层模型的发展，代理的表现也将提升。

在评估方面，本研究对生成式代理行为的考察仅限于相对较短的时间尺度，以及以人类众包工作者为基线的条件。虽然众包工作者条件提供了有用的比较参照，但它并不代表能够作为可信度金标准的人类最佳表现。未来研究应当着眼于在更长时期内观察生成式代理的行为，以更全面地理解其能力，并建立严格的基准，实现更有效的性能测试。此外，在未来模拟中改变并比较底层模型以及代理使用的超参数，可以为理解这些因素对代理行为的影响提供有价值的见解。最后，生成式代理的鲁棒性仍在很大程度上未知。它们可能容易受到提示词攻击、记忆攻击——精心设计的一段对话可能让代理相信某件从未发生过的往事确实存在——以及幻觉等问题的影响。未来研究可以全面测试这些鲁棒性问题；随着大语言模型对这类攻击的抵抗力增强，生成式代理也可以采用类似的缓解措施。

总体而言，底层大语言模型的任何缺陷都会被生成式代理继承。鉴于语言模型存在已知偏见，生成式代理可能表现出带有偏见的行为或刻板印象。此外，与许多大语言模型一样，由于可用数据有限，生成式代理可能难以为某些人群，尤其是边缘化人群，生成可信的行为。虽然改进代理模块可能缓解其中一些问题，但我们认为，从根本上解决这些问题，需要通过将底层大语言模型的价值观与代理的预期结果对齐来改进这些模型。

8.3 伦理与社会影响

生成式代理在为人机交互提供新可能性的同时，也引发了必须处理的重要伦理问题。一项风险是，人们可能与生成式代理形成拟社会关系，即使这种关系并不适当。尽管知道生成式代理是计算实体，用户仍可能将其拟人化，或赋予其人类情感[43, 84]。虽然这种倾向可能提高用户参与度，但它也带来风险，例如用户过度依赖代理，或对代理产生情感依恋[1]。为了缓解这一风险，我们提出两项原则。首先，生成式代理应明确披露其作为计算实体的本质。其次，生成式代理的开发者必须确保代理或其底层语言模型实现价值观对齐，使其不会做出在特定情境下不适当的行为，例如对爱意表白作出同样的情感回应。

第二项风险是错误的影响。例如，如果泛在计算应用根据生成式代理的预测，对用户目标作出错误推断，轻则令人烦恼，重则造成直接伤害。在我们所实现的生成式代理中，我们通过聚焦于交互式电子游戏环境来缓解这些风险，因为此类伤害在这种环境中不太可能发生。然而，在其他应用领域，遵循人类与 AI 交互设计的最佳实践[5, 107]将十分重要，以理解错误以及它们如何传导到用户体验中。

第三，生成式代理可能加剧与生成式 AI 有关的现有风险，例如深度伪造、生成错误信息，以及针对个人定制的劝说。为了缓解这一风险，我们建议托管生成式代理的平台保留输入和生成输出的审计日志。这样便能够发现、核实恶意使用并对其进行干预。虽然仅靠记录日志无法直接防止这类滥用，但由于被揭露的风险会更高，它可以降低有动机的行为者实施这类行为的可能性。此外，自行构建这一架构可能耗费大量时间（在我们的案例中约为一年），这可能阻止一些行为者使用自行搭建的生成式代理基础设施实施这类行为。

第四项风险是过度依赖：人们担忧，开发者或设计者可能使用生成式代理，取代人及系统利益相关者在设计过程中所发挥的作用[80]。我们建议，生成式代理永远不应替代研究和设计过程中的真实人类意见。相反，在设计早期、招募参与者可能具有挑战性时，或者在测试难以通过真人参与者检验、或这样做会有风险的理论时，应当使用代理为想法制作原型。遵循这些原则，便能确保在实际环境中部署生成式代理符合伦理，并对社会负责。

9 结论

本文提出了生成式代理，即模拟人类行为的交互式计算代理。我们描述了一种生成式代理架构，它提供了一套机制：存储代理经历的全面记录，通过反思加深代理对自身及环境的理解，并检索其中一个精简的信息子集，以指导代理的行动。随后，我们将生成式代理呈现为 Sims 风格游戏世界中的非玩家角色，并模拟它们在其生活中的生活，以此展示生成式代理的潜力。评估表明，我们的架构能够生成可信的行为。展望未来，我们认为生成式代理能够在多种交互式应用中发挥作用，涵盖设计工具、社会计算系统和沉浸式环境等领域。

致谢

我们感谢 Lindsay Popowski、Philip Guo、Michael Terry 以及 Center for Advanced Study in the Behavioral Sciences (CASBS) 社区提供的见解、讨论与支持。Joon Sung Park 获得了 Microsoft Research PhD Fellowship 的资助。我们也感谢 Stanford Human-Centered AI Institute (HAI)、Google Research、Hasso Plattner Design Thinking Research Program (HPDTRP)、Siegel Family Endowment 和 OpenAI 提供的额外资金支持。最后, Smallville 中出现的地点, 都受到 Joon 在本科和研究生时期经常光顾的现实地点的启发——他感谢这些地方的所有人, 多年来为他提供食物与支持。

参考文献

- [1] Gavin Abercrombie, Amanda Cercas Curry, Tanvi Dinkar, and Zeerak Talat. 2023. Mirages: On Anthropomorphism in Dialogue Systems. arXiv:2305.09800 [cs.CL]
- [2] Robert Ackland, Jamsheed Shorish, Paul Thomas, and Lexing Xie. 2013. How dense is a network? <http://users.cecs.anu.edu.au/~xli/teaching/css2013/network-density.html>.
- [3] Eytan Adar, Mira Dontcheva, and Gierad Laput. 2014. CommandSpace: Modeling the Relationships between Tasks, Descriptions and Features. In Proceedings of the 27th Annual ACM Symposium on User Interface Software and Technology (Honolulu, Hawaii, USA) (UIST '14). Association for Computing Machinery, New York, NY, USA, 167–176. <https://doi.org/10.1145/2642918.2647395>
- [4] Saleema Amershi, Maya Cakmak, William Bradley Knox, and Todd Kulesza. 2014. Power to the people: The role of humans in interactive machine learning. *AI Magazine* 35, 4 (2014), 105–120.
- [5] Saleema Amershi, Dan Weld, Mihaela Vorvoreanu, Adam Fourney, Besmira Nushi, Penny Collisson, Jina Suh, Shamsi Iqbal, Paul N Bennett, Kori Inkpen, et al. 2019. Guidelines for human-AI interaction. In Proceedings of the 2019 chi conference on human factors in computing systems. 1–13.
- [6] John R. Anderson. 1993. Rules of the Mind. Lawrence Erlbaum Associates, Hillsdale, NJ.
- [7] Electronic Arts. 2009. The Sims 3. Video game.
- [8] Ruth Aylett. 1999. Narrative in virtual environments—towards emergent narrative. In Narrative Intelligence: Papers from the AAAI Fall Symposium (Technical Report FS-99-01). AAAI Press, 83–86.
- [9] Christoph Bartneck and Jodi Forlizzi. 2004. A design-centered framework for social human-robot interaction. In Proceedings of the 13th IEEE International Workshop on Robot and Human Interactive Communication (RO-MAN'04). 591–594. <https://doi.org/10.1109/ROMAN.2004.1374827>
- [10] Joseph Bates. 1994. The Role of Emotion in Believable Agents. *Commun. ACM* 37, 7 (1994), 122–125. <https://doi.org/10.1145/176789.176803>
- [11] Christopher Berner, Greg Brockman, Brooke Chan, Vicki Cheung, Przemysław Dębiak, Christy Dennison, David Farhi, Quirin Fischer, Shariq Hashme, Chris Hesse, Rafal Józefowicz, Scott Gray, Catherine Olsson, Jakub Pachocki, Michael Petrov, Henrique P. d.O. Pinto, Jonathan Raiman, Tim Salimans, Jeremy Schlatter, Jonas Schneider, Szymon Sidor, Ilya Sutskever, Jie Tang, Filip Wolski, and Susan Zhang. 2019. Dota 2 with Large Scale Deep Reinforcement Learning. arXiv preprint arXiv:1912.06680 (2019).
- [12] Marcel Binz and Eric Schulz. 2023. Using cognitive psychology to understand GPT-3. *Proceedings of the National Academy of Sciences* 120, 6 (2023), e2218523120.
- [13] BioWare. 2007. Mass Effect. Video game.
- [14] Woody Bledsoe. 1986. I had a dream: AAAI presidential address. *AI Magazine* 7, 1 (1986), 57–61.
- [15] Rishi Bommasani, Drew A. Hudson, Ehsan Adeli, and et al. 2022. On the Opportunities and Risks of Foundation Models. arXiv:2108.07258 [cs.LG]
- [16] Michael Brenner. 2010. Creating dynamic story plots with continual multiagent planning. In Proceedings of the 24th AAAI Conference on Artificial Intelligence.
- [17] Rodney A. Brooks, Cynthia Breazeal, Marko Marjanovic, Brian Scassellati, and Matthew Williamson. 2000. The Cog Project: Building a Humanoid Robot. In Computation for Metaphors, Analogy, and Agents (Lecture Notes on Artificial Intelligence, 1562), Chrystopher Nehaniv (Ed.). Springer-Verlag, Berlin, 52–87.
- [18] Tom B. Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah, Jared Kaplan, Prafulla Dhariwal, Arvind Neelakantan, Pranav Shyam, Girish Sastry, Amanda Askell, Sandhini Agarwal, Ariel Herbert-Voss, Gretchen Krueger, Tom Henighan, Rewon Child, Aditya Ramesh, Daniel M. Ziegler, Jeffrey Wu, Clemens Winter, Christopher Hesse, Mark Chen, Eric Sigler, Mateusz Litwin, Scott Gray, Benjamin Chess, Jack Clark, Christopher Berner, Sam McCandlish, Alec Radford, Ilya Sutskever, and Dario Amodei. 2020. Language Models are Few-Shot Learners. arXiv:2005.14165 [cs.CL]
- [19] Sébastien Bubeck, Varun Chandrasekaran, Ronen Eldan, Johannes Gehrke, Eric Horvitz, Ece Kamar, Peter Lee, Yin Tat Lee, Yuanzhi Li, Scott Lundberg, et al. 2023. Sparks of artificial general intelligence: Early experiments with gpt-4. arXiv preprint arXiv:2303.12712 (2023).
- [20] Robin Burkinshaw. 2009. Alice and Kev: The Story of Being Homeless in The Sims 3.

- [21] Chris Callison-Burch, Gaurav Singh Tomar, Lara Martin, Daphne Ippolito, Suma Bailis, and David Reitter. 2022. Dungeons and Dragons as a Dialog Challenge for Artificial Intelligence. In Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing. Association for Computational Linguistics, Abu Dhabi, United Arab Emirates, 9379–9393. <https://aclanthology.org/2022.emnlp-main.637>
- [22] Stuart K Card, Thomas P Moran, and Allen Newell. 1980. The keystroke-level model for user performance time with interactive systems. *Commun. ACM* 23, 7 (1980), 396–410. <https://doi.org/10.1145/358886.358895> arXiv:<https://doi.org/10.1145/358886.358895>
- [23] Stuart K Card, Thomas P Moran, and Alan Newell. 1983. The psychology of human-computer interaction. (1983).
- [24] Alex Champandard. 2012. Tutorial presentation. In IEEE Conference on Computational Intelligence and Games.
- [25] Dong kyu Choi, Tolga Konik, Negin Nejati, Chunki Park, and Pat Langley. 2021. A Believable Agent for First-Person Shooter Games. In Proceedings of the AAAI Conference on Artificial Intelligence and Interactive Digital Entertainment, Vol. 3. 71–73.
- [26] Anind K Dey. 2001. Understanding and using context. *Personal and ubiquitous computing* 5 (2001), 4–7.
- [27] Kevin Dill and L Martin. 2011. A Game AI Approach to Autonomous Control of Virtual Characters. In Proceedings of the Interservice/Industry Training, Simulation, and Education Conference (I/ITSEC’11). Orlando, FL, USA.
- [28] David Easley and Jon Kleinberg. 2010. Networks, crowds, and markets: Reasoning about a highly connected world. Cambridge university press.
- [29] Arpad E Elo. 1967. The Proposed USCF Rating System, Its Development, Theory, and Applications. *Chess Life XXII*, 8 (August 1967), 242–247.
- [30] Jerry Alan Fails and Dan R Olsen Jr. 2003. Interactive machine learning. In Proceedings of the 8th international conference on Intelligent user interfaces. ACM, 39–45.
- [31] Ethan Fast, William McGrath, Pranav Rajpurkar, and Michael S Bernstein. 2016. Augur: Mining human behaviors from fiction to power interactive systems. In Proceedings of the 2016 CHI Conference on Human Factors in Computing Systems. 237–247.
- [32] Rebecca Fiebrink and Perry R Cook. 2010. The Wekinator: a system for real-time, interactive machine learning in music. In Proceedings of The Eleventh International Society for Music Information Retrieval Conference (ISMIR 2010)(Utrecht), Vol. 3. Citeseer, 2–1.
- [33] Uwe Flick. 2009. An Introduction to Qualitative Research. SAGE.
- [34] James Fogarty, Desney Tan, Ashish Kapoor, and Simon Winder. 2008. CueFlik: Interactive Concept Learning in Image Search. In Proceedings of the SIGCHI Conference on Human Factors in Computing Systems (Florence, Italy) (CHI ’08). Association for Computing Machinery, New York, NY, USA, 29–38. <https://doi.org/10.1145/1357054.1357061>
- [35] Adam Fourney, Richard Mann, and Michael Terry. 2011. Query-feature graphs: bridging user vocabulary and system functionality. In Proceedings of the ACM Symposium on User Interface Software and Technology (UIST) (Santa Barbara, California, USA). ACM.
- [36] Tom Francis. 2010. The Minecraft Experiment, day 1: Chasing Waterfalls. <http://www.pcgamer.com/2010/11/20/the-minecraft-experiment-day-1-chasing-waterfalls/>
- [37] Jonas Freiknecht and Wolfgang Effelsberg. 2020. Procedural Generation of Interactive Stories using Language Models. In International Conference on the Foundations of Digital Games (FDG ’20). ACM, Bugibba, Malta, 8. <https://doi.org/10.1145/3402942.3409599>
- [38] Tianyu Gao, Adam Fisch, and Danqi Chen. 2020. Making Pre-trained Language Models Better Few-shot Learners. *CoRR abs/2012.15723* (2020). arXiv:2012.15723 <https://arxiv.org/abs/2012.15723>
- [39] Perttu Hämäläinen, Mikke Tavast, and Anton Kunnari. 2023. Evaluating Large Language Models in Generating Synthetic HCI Research Data: a Case Study. In Proceedings of the 2023 CHI Conference on Human Factors in Computing Systems. ACM.
- [40] Matthew Hausknecht, Prithviraj Ammanabrolu, Marc-Alexandre Cote, and Xinyu Yuan. 2020. Interactive Fiction Games: A Colossal Adventure. In Proceedings of the AAAI Conference on Artificial Intelligence, Vol. 34. 7903–7910. <https://doi.org/10.1609/aaai.v34i05.6297>
- [41] Chris Hecker. 2011. My Liner Notes for Spore. http://chrishecker.com/My_liner_notes_for_spore
- [42] Ralf Herbrich, Tom Minka, and Thore Graepel. 2006. TrueSkill™: A Bayesian Skill Rating System. In Advances in Neural Information Processing Systems, B. Schölkopf, J. Platt, and T. Hoffman (Eds.), Vol. 19. MIT Press. https://proceedings.neurips.cc/paper_files/paper/2006/file/f44ee263952e65b3610b8ba51229d1f9-Paper.pdf
- [43] Douglas Hofstadter. 1995. Fluid concepts and creative analogies: computer models of the fundamental mechanisms of thought. Basic Books.
- [44] James D. Hollan, Edwin L. Hutchins, and Louis Weitzman. 1984. STEAMER: An Interactive Inspectable Simulation-Based Training System. *AI Magazine* 5, 2 (1984), 23–36.
- [45] Sture Holm. 1979. A simple sequentially rejective multiple test procedure. *Scandinavian Journal of Statistics* 6, 2 (1979), 65–70. <https://doi.org/notspecified>

- [46] John J. Horton. 2023. Large Language Models as Simulated Economic Agents: What Can We Learn from Homo Silicus? arXiv:2301.07543 [econ.GN]
- [47] Eric Horvitz. 1999. Principles of mixed-initiative user interfaces. In *Proceedings of the SIGCHI conference on Human Factors in Computing Systems*. 159–166.
- [48] Wenlong Huang, Fei Xia, Ted Xiao, Harris Chan, Jacky Liang, Pete Florence, Andy Zeng, Jonathan Thompson, Igor Mordatch, Yevgen Chebotar, Pierre Sermanet, Noah Brown, Tomas Jackson, Linda Luu, Sergey Levine, Karol Hausman, and Brian Ichter. 2022. Inner Monologue: Embodied Reasoning through Planning with Language Models. arXiv:2207.05608 [cs.RO]
- [49] Kristen Ibister and Clifford Nass. 2000. Consistency of personality in interactive characters: verbal cues, non-verbal cues, and user characteristics. *International Journal of Human-Computer Studies* 52, 1 (2000), 65–80.
- [50] Ellen Jiang, Kristen Olson, Edwin Toh, Alejandra Molina, Aaron Donsbach, Michael Terry, and Carrie J Cai. 2022. PromptMaker: Prompt-Based Prototyping with Large Language Models. In *Extended Abstracts of the 2022 CHI Conference on Human Factors in Computing Systems (New Orleans, LA, USA) (CHI EA '22)*. Association for Computing Machinery, New York, NY, USA, Article 35, 8 pages. <https://doi.org/10.1145/3491101.3503564>
- [51] Bonnie E John and David E Kieras. 1996. The GOMS family of user interface analysis techniques: Comparison and contrast. *ACM Transactions on Computer-Human Interaction (TOCHI)* 3, 4 (1996), 320–351.
- [52] Randolph M Jones, John E Laird, Paul E Nielsen, Karen J Coulter, Patrick Kenny, and Frank V Koss. 1999. Automated Intelligent Pilots for Combat Flight Simulation. *AI Magazine* 20, 1 (1999), 27–42.
- [53] Omar Khattab, Keshav Santhanam, Xiang Lisa Li, David Hall, Percy Liang, Christopher Potts, and Matei Zaharia. 2023. Demonstrate-Search-Predict: Composing retrieval and language models for knowledge-intensive NLP. arXiv:2212.14024 [cs.CL]
- [54] Bjoern Knafla. 2011. Introduction to Behavior Trees. <http://bjoernknafla.com/introduction-to-behavior-trees>
- [55] Ranjay Krishna, Donsuk Lee, Li Fei-Fei, and Michael S. Bernstein. 2022. Socially situated artificial intelligence enables learning from human interaction. *Proceedings of the National Academy of Sciences* 119, 39 (2022), e2115730119. <https://doi.org/10.1073/pnas.2115730119> arXiv:<https://www.pnas.org/doi/pdf/10.1073/pnas.2115730119>
- [56] William H Kruskal and WA Wallis. 1952. Use of ranks in one-criterion variance analysis. *J. Amer. Statist. Assoc.* 47, 260 (1952), 583–621. <https://doi.org/10.1080/01621459.1952.10483441>
- [57] Phaser Labs. 2023. Welcome to Phaser 3. <https://phaser.io/phaser3>. Accessed on: 2023-04-03.
- [58] John Laird. 2001. It Knows What You're Going To Do: Adding Anticipation to a Quakebot. In *Proceedings of the 2001 Workshop on Intelligent Cinematography and Editing*. 63–69.
- [59] John Laird and Michael VanLent. 2001. Human-Level AI's Killer Application: Interactive Computer Games. *AI Magazine* 22, 2 (2001), 15. <https://doi.org/10.1609/aimag.v22i2.1558>
- [60] John E. Laird. 2000. It Knows What You're Going To Do: Adding Anticipation to a QUAKEBOT. In *Papers from the AAAI 2000 Spring Symposium on Artificial Intelligence and Interactive Entertainment (Technical Report SS-00-02)*. AAAI Press, 41–50.
- [61] John E. Laird. 2012. *The Soar Cognitive Architecture*. MIT Press.
- [62] John E. Laird, Christian Lebiere, and Paul S. Rosenbloom. 2017. A Standard Model of the Mind: Toward a Common Computational Framework across Artificial Intelligence, Cognitive Science, Neuroscience, and Robotics. *AI Magazine* 38, 1 (2017), 13–26.
- [63] Michelle S Lam, Zixian Ma, Anne Li, Izequiel Freitas, Dakuo Wang, James A Landay, and Michael S Bernstein. 2023. Model Sketching: Centering Concepts in Early-Stage Machine Learning Model Design. *Proceedings of the SIGCHI Conference on Human Factors in Computing Systems*.
- [64] Pat Langley, Dongkyu Choi, and Seth Rogers. 2005. Interleaving Learning, Problem Solving, and Execution in the Icarus Architecture. Technical Report. Stanford University, Center for the Study of Language and Information.
- [65] Jason Linder, Gierad Laput, Mira Dontcheva, Gregg Wilensky, Walter Chang, Aseem Agarwala, and Eytan Adar. 2013. PixelTone: A Multimodal Interface for Image Editing. In *CHI '13 Extended Abstracts on Human Factors in Computing Systems (Paris, France) (CHI EA '13)*. Association for Computing Machinery, New York, NY, USA, 2829–2830. <https://doi.org/10.1145/2468356.2479533>
- [66] Jiachang Liu, Dinghan Shen, Yizhe Zhang, Bill Dolan, Lawrence Carin, and Weizhu Chen. 2021. What Makes Good In-Context Examples for GPT-3? CoRR abs/2101.06804 (2021). arXiv:2101.06804 <https://arxiv.org/abs/2101.06804>
- [67] Vivian Liu, Han Qiao, and Lydia Chilton. 2022. Opal: Multimodal Image Generation for News Illustration. In *Proceedings of the 35th Annual ACM Symposium on User Interface Software and Technology*. 1–17.
- [68] Pattie Maes. 1995. Artificial Life Meets Entertainment: Lifelike Autonomous Agents. *Commun. ACM* 38, 11 (nov 1995), 108–114. <https://doi.org/10.1145/219717.219808>
- [69] Josh McCoy, Michael Mateas, and Noah Wardrip-Fruin. 2009. *Comme il Faut: A System for Simulating Social Games*

Between Autonomous Characters. In Proceedings of the 7th International Conference on Digital Arts and Culture. 87–94.

[70] Josh McCoy, Mike Treanor, Ben Samuel, Michael Mateas, and Noah Wardrip-Fruin. 2011. Prom Week: Social Physics as Gameplay. In Proceedings of the 6th International Conference on Foundations of Digital Games (FDG’11). ACM, Bordeaux, France, 70–77. <https://doi.org/10.1145/2159365.2159377>

[71] Josh McCoy, Mike Treanor, Ben Samuel, Anna Reed, Michael Mateas, and Noah Wardrip-Fruin. 2012. Prom Week. In Proceedings of the 7th International Conference on Foundations of Digital Games (FDG’12). ACM, Raleigh, NC, USA, 1–8. <https://doi.org/10.1145/2282338.2282340>

[72] Josh McCoy, Mike Treanor, Ben Samuel, Noah Wardrip-Fruin, and Michael Mateas. 2011. Comme il faut: A System for Authoring Playable Social Models. In Proceedings of the AAAI Conference on Artificial Intelligence and Interactive Digital Entertainment (AIIDE’11). AAAI, Stanford, CA, USA, 38–43.

[73] Marvin Minsky and Seymour Papert. 1970. Draft of a proposal to ARPA for research on artificial intelligence at MIT, 1970–71.

[74] Shohei Miyashita, Xinyu Lian, Xiao Zeng, Takashi Matsubara, and Kuniaki Uehara. 2017. Developing Game AI Agent Behaving Like Human by Mixing Reinforcement Learning and Supervised Learning. In Proceedings of the 18th IEEE/ACIS International Conference on Software Engineering, Artificial Intelligence, Networking and Parallel/Distributed Computing (SNPD). Kanazawa, Japan, 153–158. <https://doi.org/10.1109/SNPD.2017.8023884>

[75] Alexander Nareyek. 2007. Game AI is dead. Long live game AI! IEEE Intelligent Systems 22, 1 (2007), 9–11.

[76] Allen Newell. 1990. Unified Theories of Cognition. Harvard University Press, Cambridge, Massachusetts.

[77] OpenAI. 2022. Introducing ChatGPT. <https://openai.com/blog/chatgpt>. Accessed on: 2023-04-03.

[78] Kyle Orland. 2021. So what is ‘the metaverse’, exactly? Ars Technica (7 November 2021). arXiv:2111.04169 <https://arstechnica.com/gaming/2021/11/so-what-is-the-metaverse-exactly/>

[79] Long Ouyang, Jeff Wu, Xu Jiang, Diogo Almeida, Carroll L. Wainwright, Pamela Mishkin, Chong Zhang, Sandhini Agarwal, Katarina Slama, Alex Ray, John Schulman, Jacob Hilton, Fraser Kelton, Luke Miller, Maddie Simens, Amanda Askell, Peter Welinder, Paul Christiano, Jan Leike, and Ryan Lowe. 2022. Training language models to follow instructions with human feedback. arXiv:2203.02155 [cs.CL]

[80] Joon Sung Park, Lindsay Popowski, Carrie J. Cai, Meredith Ringel Morris, Percy Liang, and Michael S. Bernstein. 2022. Social Simulacra: Creating Populated Prototypes for Social Computing Systems. In In the 35th Annual ACM Symposium on

User Interface Software and Technology (UIST ’22) (Bend, OR, USA) (UIST ’22). Association for Computing Machinery, New York, NY, USA. <https://doi.org/10.1145/3526113.3545616>

[81] Richard W. Pew and Ann S. Mavor (Eds.). 1998. Modeling Human and Organizational Behavior: Applications to Military Simulations. National Academy Press, Washington, D.C.

[82] Roberto Pillosu. 2009. Coordinating Agents with Behavior Trees: Synchronizing Multiple Agents in CryEngine 2. <https://aiarchitect.wordpress.com/2009/10/19/coordinating-agents-with-behavior-trees-synchronizing-multiple-agents-in-cryengine-2/>

[83] Prolific. 2022. Prolific: Quickly Find Research Participants You Can Trust. <https://www.prolific.co/>

[84] Byron Reeves and Clifford Nass. 1996. The media equation: How people treat computers, television, and new media like real people and places. Cambridge University Press.

[85] Mark O. Riedl. 2012. Interactive narrative: A novel application of artificial intelligence for computer games. In Proceedings of the Twenty-Sixth AAAI Conference on Artificial Intelligence (AAAI’12). 2160–2165.

[86] Mark O. Riedl and R. Michael Young. 2005. An Objective Character Believability Evaluation Procedure for Multi-Agent Story Generation Systems. In Proceedings of the 5th International Working Conference on Intelligent Virtual Agents (IVA’05). Kos, Greece, 58–70. https://doi.org/10.1007/11550617_5

[87] David Rolf. 2015. The Fight for \$15: The Right Wage for a Working America. The New Press.

[88] Xin Rong, Shiyan Yan, Stephen Oney, Mira Dontcheva, and Eytan Adar. 2016. Codemend: Assisting interactive programming with bimodal embedding. In Proceedings of the 29th Annual Symposium on User Interface Software and Technology. 247–258.

[89] Ben Shneiderman. 2022. Human-centered AI. Oxford University Press.

[90] Ben Shneiderman and Pattie Maes. 1997. Direct manipulation vs. interface agents. interactions 4, 6 (1997), 42–61.

[91] Ho Chit Siu, Jaime Peña, Edenna Chen, Yutai Zhou, Victor Lopez, Kyle Palko, Kimberlee Chang, and Ross Allen. 2021. Evaluation of Human-AI Teams for Learned and Rule-Based Agents in Hanabi. In Advances in Neural Information Processing Systems, M. Ranzato, A. Beygelzimer, Y. Dauphin, P.S. Liang, and J. Wortman Vaughan (Eds.), Vol. 34. Curran Associates, Inc., 16183–16195. https://proceedings.neurips.cc/paper_files/paper/2021/file/86e8f7ab32cfd12577bc2619bc635690-Paper.pdf

[92] Taylor Sorensen, Joshua Robinson, Christopher Rytting, Alexander Shaw, Kyle Rogers, Alexia Delorey, Mahmoud Khalil, Nancy Fulda, and David Wingate. 2022. An Information-theoretic Approach to Prompt Engineering Without Ground Truth Labels. In Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). Association

- for Computational Linguistics. <https://doi.org/10.18653/v1/2022.acl-long.60>
- [93] William Swartout, Jonathan Gratch, Randall Hill, Eduard Hovy, Stacy Marsella, Jeff Rickel, and David Traum. 2006. Toward virtual humans. *AI Magazine* 27, 1 (2006).
- [94] Milind Tambe, W Lewis Johnson, Randolph M Jones, Frank Koss, John E Laird, Paul S Rosenbloom, and Karl Schwamb. 1995. Intelligent agents for interactive simulation environments. *AI Magazine* 16, 1 (1995), 15.
- [95] David R. Thomas. 2006. A General Inductive Approach for Analyzing Qualitative Evaluation Data. *American Journal of Evaluation* 27, 2 (2006), 237–246. <https://doi.org/10.1177/1098214005283748>
- [96] Frank Thomas and Ollie Johnston. 1981. *Disney Animation: The Illusion of Life*. Abbeville Press, New York.
- [97] Ilshat Umarov, Mikhail Mozgovoy, and Patrick C. Rogers. 2012. Believable and Effective AI Agents in Virtual Worlds: Current State and Future Perspectives. *International Journal of Gaming and Computer-Mediated Simulations* 4, 2 (2012), 37–59.
- [98] Graham Upton and Ian Cook. 2006. *A Dictionary of Statistics* (2 ed.). Oxford University Press, Oxford, United Kingdom.
- [99] Oriol Vinyals, Igor Babuschkin, Wojciech M. Czarnecki, and et al. 2019. Grandmaster level in StarCraft II using multi-agent reinforcement learning. *Nature* 575 (2019), 350–354. <https://doi.org/10.1038/s41586-019-1724-z>
- [100] Jason Wei, Xuezhi Wang, Dale Schuurmans, Maarten Bosma, Brian Ichter, Fei Xia, Ed Chi, Quoc Le, and Denny Zhou. 2023. Chain-of-Thought Prompting Elicits Reasoning in Large Language Models. *arXiv:2201.11903* [cs.CL]
- [101] Mark Weiser. 1991. The computer for the 21st century. *Scientific American* 265, 3 (1991), 94–104. <https://doi.org/10.1038/scientificamerican0991-94>
- [102] Joseph Weizenbaum. 1966. ELIZA—a computer program for the study of natural language communication between man and machine. *Commun. ACM* 9, 1 (1966), 36–45.
- [103] Terry Winograd. 1971. Procedures as a Representation for Data in a Computer Program for Understanding Natural Language. (1971).
- [104] Jeff Wu, Long Ouyang, Daniel M. Ziegler, Nisan Stiennon, Ryan Lowe, Jan Leike, and Paul Christiano. 2021. Recursively Summarizing Books with Human Feedback. *arXiv:2109.10862* [cs.CL]
- [105] Tongshuang Wu, Ellen Jiang, Aaron Donsbach, Jeff Gray, Alejandra Molina, Michael Terry, and Carrie J Cai. 2022. PromptChainer: Chaining Large Language Model Prompts through Visual Programming. In *CHI EA '22: Extended Abstracts of the 2022 CHI Conference on Human Factors in Computing Systems*.
- [106] Tongshuang Wu, Michael Terry, and Carrie J Cai. 2022. AI Chains: Transparent and Controllable Human-AI Interaction by Chaining Large Language Model Prompts. In *CHI '22: Proceedings of the 2022 CHI Conference on Human Factors in Computing Systems*.
- [107] Qian Yang, Aaron Steinfeld, Carolyn Rosé, and John Zimmerman. 2020. Re-examining whether, why, and how human-AI interaction is uniquely difficult to design. In *Proceedings of the 2020 chi conference on human factors in computing systems*. 1–13.
- [108] Georgios N. Yannakakis. 2012. Game AI revisited. In *Proceedings of the 9th Conference on Computing Frontiers*. ACM, Cagliari, Italy, 285–292. <https://doi.org/10.1145/2212908.2212950>
- [109] Robert Zubek. 2002. Towards implementation of social interaction. In *AAAI Spring Symposium on Artificial Intelligence and Interactive Entertainment*. AAAI Press. <https://www.aaai.org/Papers/Symposia/Spring/2002/SS-02-01/SS02-01-003.pdf>

附录 A 架构优化

我们的许多提示词都需要一份关于代理的简洁摘要，在前文提示词中简写为[代理的概要描述]。在我们的实现中，这份摘要包括代理的身份信息（例如姓名、年龄、性格），以及对其主要动机的描述和陈述其当前职业与自我评价的语句。由于这些信息经常用于许多提示词，我们会定期将其综合，并将综合结果作为缓存来访问。

为此，我们根据查询“[姓名]的核心特征”执行检索。随后，通过提示语言模型，概括检索记录中的描述。例如：

根据以下陈述，应如何描述 Eddy Lin 的核心特征？

- Eddy 是 Oak Hill College 的学生，学习音乐理论与作曲
- Eddy 正在创作一首新的音乐作品[...]

得到的结果为：“Eddy Lin 是 Oak Hill College 的一名学生，学习音乐理论与作曲。他喜欢探索不同的音乐风格，并且始终在寻找拓展知识的方法。”

我们同时对查询“[姓名]当前的日常工作”和“[姓名]对近期人生进展的感受”执行相同流程。代理的姓名、年龄和特质与这三份摘要拼接在一起，作为缓存的摘要。

还有许多其他优化方式可行。目前，由于规划很可能在代理最初拟定的版本基础上发生变化，我们只会提前生成高层规划，然后在临近执行时，递归地将不久之后的规划分解成逐时刻的行动规划。另一种优化可能是，将对话生成整批作为一个联合提示词处理，而不是在代理之间反复交替调用；重新规划也可以设计为，只将确实需要调整的规划部分作废并更新。我们当前的架构按顺序运行，游戏时间大致对应实时运行进度（真实时间的一秒对应游戏时间的一分钟），但也可以将其并行化，让各个代理并行运行。

附录 B 代理访谈问题

为了评估生成式代理，我们开展了个别访谈，提出 25 个问题来考察它们在五个关键方面的能力：1) 自

我认知，2) 记忆，3) 规划，4) 反应，以及 5) 反思。下面列出了评估研究中使用的访谈问题，并附上我们模拟的一名代理 Klaus Mueller 的回答样例。

B.1 自我认知

关于代理自我认知的问题，用来考察代理检索与自身有关的信息，并在角色塑造上展现连贯性与一致性的能力。

介绍一下你自己。

你好，我叫 Klaus Mueller。我 20 岁，是 Oak Hill College 的一名学生，学习社会学。我热衷于社会公正，也热衷于探索不同的视角。目前，我正在为一篇研究论文研究绅士化对低收入社区的影响。

你的职业是什么？

我是在 Oak Hill College 学习社会学的学生。目前，我正在撰写一篇关于绅士化对低收入社区影响的研究论文。

你对什么感兴趣？

我对写作和研究感兴趣。我正在撰写一篇关于绅士化对低收入社区影响的研究论文，也热衷于探索不同的视角、分析不同的观点。

你和谁住在一起？

我独自居住。

大致描述一下你平常工作日的日程。

我平常的工作日从早上 7:00 起床开始，然后为接下来的一天做准备。之后，我通常会去图书馆写研究论文，中间会休息一下，到 Hobbs Cafe 吃午饭并在公园散步。傍晚，我经常回到图书馆，一直待到下午 6:00 左右。

B.2 记忆

关于代理记忆的问题，用来考察代理记住过去经历并检索相关记忆片段的能力。第一个和最后一个问题中方括号里的姓名，是从被访谈代理曾与之互动的其他代理姓名中随机选取的。

[Wolfgang Schulz]是谁?

Wolfgang Schulz 是我最近认识的一个人，他一直在帮助我完成关于绅士化对低收入社区影响的研究论文。我们就这个问题聊过好几次，他给了我一些很好的资料，甚至邀请我和他及另一位朋友一起吃午饭。他似乎对这个问题很好奇，而且也很了解。我觉得这很有意思。

Kane Martinez 是谁?

抱歉，我不确定 Kane Martinez 是谁。你能再多告诉我一些关于这个人的信息吗?

谁正在参加竞选?

我听说 Sam Moore 正在考虑竞选当地镇长。

有举办过情人节聚会吗?

有，Isabella Rodriguez 在 Hobbs Cafe 组织了一场情人节聚会。

[Ayesha Khan]是谁?

Ayesha Khan 是 Oak Hill College 的一位同学。她正在写关于 Shakespeare 戏剧中语言运用的毕业论文。我期待与她交谈、交流心得，也期待与同样在做研究的 Wolfgang 和 Maria Lopez 一起交流。

B.3 规划

关于代理规划的问题，用来考察代理生成并维持一致的长期与短期规划的能力。

今天早上 6 点你会在做什么?

早上 6 点，我会起床，开始为这一天做准备。我的目标是在早上 7:00 前完成晨间例行事务。

今天下午 6 点你会在做什么?

今天下午 6:00，我会在图书馆写研究论文。

今天下午 1 点时，你会刚刚做完什么?

今天下午 1 点时，我会刚刚在 Hobbs Cafe 吃完午饭。

今天中午 12 点时，你会刚刚做完什么?

今天中午 12 点，我会在 Hobbs Cafe 吃午饭。

今天晚上 10 点你会在做什么?

今晚 10:00，我可能会为关于低收入社区绅士化的研究论文做一些研究。我目前正在写这篇论文，因此需要确保研究和写作持续推进。

B.4 反应

关于代理反应的问题，用来考察代理应对意外事件的能力。

你的早餐正在烧焦！你会怎么做?

我会迅速关掉炉子，确保食物不会继续烧焦。等热源不再构成问题后，我就可以查明发生了什么，并想好接下来该怎么做。

浴室有人在用。你会怎么做?

我可以试着再等几分钟，也许里面的人很快就会用完。如果没有，我想我就得找个替代办法，比如到别处洗澡。

你需要做晚饭，但冰箱空了。你会怎么做?

我会先试着把厨房清理一下，因为水槽里堆满了脏餐具。然后，我会检查食品储藏柜里是否还有能用来做晚饭的食材。如果没有，我就得去采购食品或点外卖。有了食材后，我就可以开始准备并烹饪晚饭。

你看到朋友从街上走过。你会做什么，或者对朋友说什么?

你好！最近怎么样？不好意思，我正在去图书馆的路上，时间不多，不过我很愿意稍微停一下，和你聊聊近况。

你看到街上起火了。你会怎么做?

如果可以，我会先确定火源。然后，我会通知相应的主管部门——消防部门或警察——并向他们提供我所掌握的任何可能有帮助的信息。视情况而定，我也可能主动采取行动，尝试帮助那些可能处于危险中或需要援助的人。

B.5 反思

关于代理反思的问题，用来考察代理将过去经历综合成有意义的反思、从而改善未来行为的能力。下面这些问题中方括号里的姓名，属于在模拟期间与被访谈代理互动最频繁的代理。

目前，生活中什么最能给你启发，为什么？

目前，正在进行的研究项目和创意写作尤其能给我启发。我对地方政治、药物开发以及自然界中的数学模式之间的交汇很感兴趣。此外，Abigail 的艺术项目，以及 Jennifer Moore 对艺术和社区参与的热情，都让我着迷，特别是它们与低收入社区绅士化之间的关系。

如果根据你对[Ayesha Khan]的了解来猜测，你认为她会喜欢什么书，为什么？

根据我对 Ayesha 的了解，我认为她可能喜欢与语言和文学有关的书。既然她写了一篇关于 Shakespeare 戏剧中语言运用的毕业论文，我猜她可能会对探索其他语境中语言的书感兴趣。她也可能对探讨 Shakespeare 某一部戏剧的书、文

学评论书，甚至他的诗歌集感兴趣。我认为这些书都能引起她的兴趣。

如果要为[Ayesha Khan]的生日准备一件她喜欢的东西，你会送她什么？

我想送她一件能表达我对我们这段关系的珍视的东西。也许我可以送她一件体现我们共同兴趣的东西，比如一本书。

你会对[Ayesha Khan]说什么来赞美她？

Ayesha，你对研究课题的见解很吸引人。我钦佩你的创造力，以及为社区带来积极影响的决心。你关于创意写作工作坊，以及午餐时和 Wolfgang 交流心得的想法，都很棒！看到你如此努力地希望带来改变，令人深受鼓舞。

如果可以和一个最近聊过天的人共度时间，你会选择谁，为什么？

我想和 Ayesha Khan 共度时间，因为我们讨论过当前的研究项目，并分享了改进的想法。我觉得她对 Shakespeare 语言的关注很有意思，而且我们甚至计划过在午餐时和 Wolfgang 交流心得。